

ĐẠI HỌC THÁI NGUYÊN
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÁO CÁO CHUYÊN ĐỀ 1

Đề tài:

**PHÂN TÍCH ĐÁNH GIÁ CỦA KHÁCH HÀNG TRÊN
CÁC TRANG THƯƠNG MẠI ĐIỆN TỬ ĐỂ THU THẬP
PHẢN HỒI CỦA KHÁCH HÀNG VỀ SẢN PHẨM**

Sinh viên thực hiện: LÊ THỊ KIM NGÂN

Lớp:

Giáo viên hướng dẫn:

THÁI NGUYÊN, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành đến thầy **GVHD**, người đã định hướng, hướng dẫn và góp ý cho em trong quá trình lựa chọn đề tài, xây dựng đề cương và hoàn thiện nội dung báo cáo chuyên đề. Những nhận xét của thầy giúp em hiểu rõ hơn yêu cầu của một đề tài ứng dụng trí tuệ nhân tạo trong thực tế, đặc biệt là cách mô hình hóa bài toán, xác định phạm vi sản phẩm và trình bày kết quả nghiên cứu một cách khoa học.

Em xin cảm ơn các thầy cô giáo Trường Đại học Công nghệ Thông tin và Truyền thông - Đại học Thái Nguyên đã truyền đạt cho em những kiến thức nền tảng về lập trình, cơ sở dữ liệu, học máy, học sâu và phát triển ứng dụng web. Đây là những kiến thức quan trọng giúp em có thể triển khai đề tài “Phân tích đánh giá của khách hàng trên các trang thương mại điện tử để thu thập phản hồi của khách hàng về sản phẩm”.

Do thời gian thực hiện và kinh nghiệm nghiên cứu còn hạn chế, báo cáo không tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của thầy cô để đề tài có thể tiếp tục được hoàn thiện trong các giai đoạn sau.

Xin chân thành cảm ơn!

Thái Nguyên, ngày tháng năm 2026

Sinh viên

Lê Thị Kim Ngân

MỤC LỤC

LỜI MỞ ĐẦU	7
CHƯƠNG 1. TỔNG QUAN VÀ CƠ SỞ LÝ THUYẾT	9
1.1. Tổng quan về thương mại điện tử và dữ liệu đánh giá sản phẩm	9
1.2. Bài toán phân tích cảm xúc khách hàng.....	9
1.3. Xử lý ngôn ngữ tự nhiên tiếng Việt	10
1.4. Học máy trong phân loại văn bản	11
1.5. Học sâu và mô hình tuần tự.....	12
1.6. Transformer, BERT, RoBERTa và PhoBERT	12
1.6.1. Kiến trúc Transformer	12
1.6.2. BERT và RoBERTa.....	12
1.6.3. PhoBERT và lý do lựa chọn cho đề tài.....	13
1.7. Thu thập dữ liệu từ website thương mại điện tử	14
1.8. Dashboard và trợ lý dữ liệu trong phân tích phản hồi.....	Error! Bookmark not defined.
1.9. Các chỉ số đánh giá mô hình	Error! Bookmark not defined.
CHƯƠNG 2. PHƯƠNG PHÁP, MÔ HÌNH VÀ THIẾT KẾ HỆ THỐNG	16
2.1. Phân tích bài toán và mô hình hóa đầu vào - đầu ra	16
2.2. Các hướng nghiên cứu liên quan đến phân tích cảm xúc tiếng Việt.....	16
2.2.1. Nhóm phương pháp TF-IDF và bộ phân loại cổ điển	17
2.2.2. Nhóm mô hình tuần tự: LSTM, BiLSTM và attention.....	17
2.2.3. Mô hình Transformer và hướng tiền huấn luyện ngôn ngữ.....	18
2.3. Nguồn dữ liệu và cách hình thành nhãn cảm xúc	19
2.4. Tiền xử lý tiếng Việt và biểu diễn đầu vào	22
2.5. Baseline TF-IDF + SVM và vai trò kiểm chứng dữ liệu	24
2.6. Từ mô hình tuần tự đến Transformer trong bài toán review....	Error! Bookmark not defined.
2.7. Cơ sở chọn PhoBERT cho dữ liệu review tiếng Việt	25
2.8. Chỉ số đánh giá và quy trình thực nghiệm	26
2.9. Thiết kế hệ thống tích hợp crawler, mô hình và dashboard	28
CHƯƠNG 3. THỰC NGHIỆM, ĐÁNH GIÁ VÀ KẾT LUẬN	32
3.1. Mục tiêu thực nghiệm và phạm vi đánh giá.....	32
3.2. Môi trường thực nghiệm và công cụ triển khai.....	32
3.3. Dữ liệu thực nghiệm sau thu thập và làm sạch	33
3.4. Quy trình tiền xử lý và chia tập dữ liệu	34

3.5. Thiết lập thực nghiệm cho các mô hình	35
3.5.1. Baseline TF-IDF + SVM	35
3.5.2. LSTM/BiLSTM	36
3.5.3. PhoBERT fine-tuning	36
3.6. Kết quả thực nghiệm phân loại cảm xúc	37
3.7. Ma trận nhầm lẫn và phân tích lỗi.....	38
3.8. Triển khai hệ thống	43
3.9. Kiểm thử chức năng hệ thống	44
3.10. Đánh giá tổng hợp và thảo luận	Error! Bookmark not defined.
TÀI LIỆU THAM KHẢO	47

MỤC LỤC HÌNH ẢNH

Hình 3. 1 Phân bố số lượng review theo nhãn.....	34
Hình 3. 2 Pipeline tiền xử lý và chia dữ liệu	35
Hình 3. 3 So sánh hiệu suất của các mô hình	39
Hình 3. 4 So sánh thời gian xử lý	40
Hình 3. 5 Quá trình huấn luyện mô hình Phobert	41
Hình 3. 6 Confusion Matrix của mô hình tốt nhất.....	42
Hình 3. 7 Giao diện dashboard phân tích review	43
Hình 3. 8 Giao diện crawl reviews	43
Hình 3. 9 Giao diện danh sách đã đánh giá	44
Hình 3. 10 Giao diện AI chatbot	44

MỤC LỤC BẢNG

Bảng 1.1. So sánh các hướng tiếp cận cho bài toán phân tích cảm xúc tiếng Việt	16
Bảng 2.1. So sánh khái quát các nhóm phương pháp phân tích cảm xúc	24
Bảng 2.2. Đặc điểm các nguồn dữ liệu sử dụng trong đề tài.....	26
Bảng 2.3. Quy tắc gán nhãn sentiment sử dụng trong đề tài	26
Bảng 2.4. Các thống kê dữ liệu cần báo cáo sau khi làm sạch.....	27
Bảng 2.5. So sánh các lựa chọn mô hình trong thiết kế thực nghiệm	34
Bảng 2.6. Các chỉ số đánh giá sử dụng trong đề tài	36
Bảng 2.7. Thành phần chính trong kiến trúc hệ thống đề xuất.....	40
Bảng 3.1. Môi trường thực nghiệm và công cụ sử dụng	43
Bảng 3.2. Thống kê dữ liệu trước và sau làm sạch	45
Bảng 3.3. Phân bố nhãn sentiment	45
Bảng 3.4. Ví dụ review trước và sau tiền xử lý	47
Bảng 3.5. Cấu hình thực nghiệm của các mô hình.....	49
Bảng 3.6. Kết quả so sánh các mô hình.....	50
Bảng 3.7. Ví dụ dự đoán sai và nguyên nhân.....	52
Bảng 3.8. Các API chính của hệ thống.....	55
Bảng 3.9. Kịch bản kiểm thử chức năng	56

LỜI MỞ ĐẦU

Trong bối cảnh thương mại điện tử phát triển mạnh mẽ, các đánh giá và phản hồi của khách hàng trên Shopee, Lazada, Tiki chứa nhiều thông tin quan trọng về chất lượng sản phẩm và mức độ hài lòng của người dùng. Tuy nhiên, việc tổng hợp và phân tích thủ công số lượng lớn bình luận tốn nhiều thời gian và khó đảm bảo tính chính xác. Vì vậy, cần xây dựng một hệ thống tự động thu thập và phân tích cảm xúc từ đánh giá khách hàng. Với sự hỗ trợ của trí tuệ nhân tạo, học máy, học sâu và các mô hình xử lý ngôn ngữ tiếng Việt như PhoBERT, hệ thống có thể phân loại phản hồi thành tích cực, tiêu cực hoặc trung lập, giúp người bán và doanh nghiệp hiểu rõ nhu cầu khách hàng và hỗ trợ ra quyết định hiệu quả hơn.

Xuất phát từ nhu cầu thực tiễn đó, đề tài “Phân tích đánh giá của khách hàng trên các trang thương mại điện tử để thu thập phản hồi của khách hàng về sản phẩm” được thực hiện nhằm xây dựng một hệ thống web hoàn chỉnh, có khả năng thu thập dữ liệu đánh giá, phân tích cảm xúc bằng mô hình AI, lưu trữ kết quả, hiển thị dashboard và hỗ trợ truy vấn dữ liệu thông qua chatbot/data assistant.

Lý do chọn đề tài

Thị trường thương mại điện tử ngày càng cạnh tranh khiến việc phân tích phản hồi khách hàng trở nên quan trọng đối với doanh nghiệp và người bán. Các đánh giá trên Shopee, Lazada, Tiki không chỉ phản ánh mức độ hài lòng mà còn cung cấp thông tin về chất lượng sản phẩm, vận chuyển và dịch vụ. Tuy nhiên, việc đọc và tổng hợp thủ công số lượng lớn bình luận mất nhiều thời gian và khó đạt hiệu quả. Vì vậy, xây dựng hệ thống tự động thu thập và phân tích đánh giá khách hàng là cần thiết. Đề tài đồng thời giúp vận dụng các kiến thức về xử lý ngôn ngữ tự nhiên, học máy, học sâu, crawling dữ liệu, thiết kế API và xây dựng dashboard trực quan trong thực tế.

Mục tiêu nghiên cứu

Mục tiêu của đề tài là xây dựng hệ thống web cho phép tự động thu thập đánh giá sản phẩm từ các sàn thương mại điện tử và phân tích cảm xúc khách hàng dựa trên nội dung bình luận. Hệ thống hỗ trợ người dùng theo dõi xu hướng phản hồi thông qua dashboard trực quan và chatbot hỗ trợ truy vấn dữ liệu.

Các mục tiêu cụ thể gồm: xây dựng module crawler thu thập review và rating; tiền xử lý dữ liệu tiếng Việt; xây dựng mô hình phân tích cảm xúc với ba nhãn tích cực, tiêu cực và trung lập; fine-tune mô hình PhoBERT cho dữ liệu tiếng Việt; phát triển API dự đoán sentiment và dashboard thống kê kết quả.

Mô hình được đánh giá bằng các chỉ số Accuracy, Precision, Recall, F1-score và Confusion Matrix, với mục tiêu đạt Accuracy và F1-score từ 85% trở lên.

Phạm vi và đối tượng nghiên cứu

Phạm vi dữ liệu của đề tài tập trung vào các đánh giá sản phẩm tiếng Việt được thu thập từ các sàn thương mại điện tử phổ biến như Shopee, Lazada và Tiki. Ngoài dữ liệu crawl thực tế, hệ thống có thể sử dụng thêm các bộ dữ liệu công khai tiếng Việt như UIT-VSFC, UIT-VISFD hoặc các bộ dữ liệu review thương mại điện tử để huấn luyện và đánh giá mô hình.

Phạm vi mô hình tập trung vào bài toán phân loại cảm xúc tổng quát ở mức câu hoặc đoạn review, với ba nhãn chính là tiêu cực, trung lập và tích cực. Đề tài chưa đi sâu vào phân tích cảm xúc theo khía cạnh chi tiết như pin, camera, giao hàng hoặc giá cả, nhưng phần hướng phát triển có đề xuất mở rộng theo hướng aspect-based sentiment analysis.

Đối tượng sử dụng hệ thống là người bán hàng trên sàn thương mại điện tử, nhân sự chăm sóc khách hàng, quản lý sản phẩm, người nghiên cứu thị trường và sinh viên muốn tìm hiểu ứng dụng AI trong phân tích dữ liệu phản hồi. Hệ thống được xây dựng ở mức prototype phục vụ nghiên cứu và demo, nhưng có thể phát triển thành sản phẩm hoàn chỉnh trong tương lai.

Phương pháp nghiên cứu

Đề tài sử dụng phương pháp nghiên cứu kết hợp giữa khảo sát lý thuyết và xây dựng thử nghiệm. Trước hết, các kiến thức nền tảng về xử lý ngôn ngữ tự nhiên, phân tích cảm xúc, mô hình học máy, học sâu và Transformer được tổng hợp để làm cơ sở lựa chọn giải pháp. Tiếp theo, dữ liệu review được thu thập, chuẩn hóa và tổ chức thành định dạng phù hợp cho huấn luyện mô hình.

Về kỹ thuật mô hình, đề tài đề xuất thử nghiệm nhiều hướng tiếp cận gồm mô hình học máy truyền thống như Logistic Regression, SVM hoặc Random Forest; mô hình học sâu như LSTM/GRU; và mô hình ngôn ngữ tiền huấn luyện PhoBERT. Kết quả giữa các mô hình được so sánh dựa trên độ chính xác, F1-score, thời gian huấn luyện và thời gian phản hồi.

Về xây dựng ứng dụng, hệ thống được thiết kế theo kiến trúc web gồm frontend, backend, tầng xử lý AI và database. Backend cung cấp các API cho crawler, dự đoán sentiment, phân tích sản phẩm, lấy dữ liệu dashboard và chatbot. Frontend hiển thị các biểu đồ, bảng review và giao diện truy vấn dữ liệu.

CHƯƠNG 1. TỔNG QUAN VÀ CƠ SỞ LÝ THUYẾT

1.1. Tổng quan về thương mại điện tử và dữ liệu đánh giá sản phẩm

Thương mại điện tử ngày càng phát triển khiến đánh giá của khách hàng trên Shopee, Lazada, Tiki trở thành nguồn thông tin quan trọng giúp người mua đưa ra quyết định và hỗ trợ người bán cải thiện sản phẩm, dịch vụ. Nội dung review không chỉ phản ánh mức độ hài lòng mà còn cho biết các vấn đề về chất lượng sản phẩm, giao hàng, đóng gói và chăm sóc khách hàng.

Tuy nhiên, số lượng đánh giá rất lớn nên việc đọc và tổng hợp thủ công mất nhiều thời gian, dễ bỏ sót thông tin quan trọng. Vì vậy, cần có hệ thống tự động thu thập, phân tích và tổng hợp phản hồi khách hàng để hỗ trợ đánh giá sản phẩm hiệu quả hơn. Bài toán phân tích review tiếng Việt cũng gặp nhiều khó khăn do dữ liệu chứa từ viết tắt, teencode, emoji, câu ngắn hoặc cảm xúc pha trộn. Điều này đòi hỏi hệ thống phải kết hợp các kỹ thuật xử lý ngôn ngữ tự nhiên và mô hình học máy/học sâu để phân tích chính xác cảm xúc của người dùng.

1.2. Bài toán phân tích cảm xúc khách hàng

Phân tích cảm xúc là quá trình xác định thái độ hoặc cảm nhận của người dùng đối với sản phẩm hay dịch vụ thông qua nội dung văn bản. Trong thương mại điện tử, dữ liệu đánh giá giúp phản ánh mức độ hài lòng của khách hàng về sản phẩm, giao hàng và trải nghiệm mua sắm.

Trong đề tài này, bài toán được xây dựng theo hướng phân loại văn bản thành ba nhãn: tích cực (positive), tiêu cực (negative) và trung lập (neutral). Đầu vào là nội dung đánh giá tiếng Việt và đầu ra là nhãn cảm xúc tương ứng. Ví dụ, các bình luận khen chất lượng sản phẩm sẽ được gán nhãn tích cực, trong khi các phản hồi về lỗi sản phẩm hoặc trải nghiệm không tốt sẽ được gán nhãn tiêu cực.

Mô hình được đánh giá thông qua các chỉ số Accuracy, Precision, Recall, F1-score và Confusion Matrix. Trong đó, F1-score và ma trận nhầm lẫn đóng vai trò quan trọng nhằm đánh giá khả năng nhận diện chính xác các lớp cảm xúc, đặc biệt với các lớp có số lượng dữ liệu ít như negative hoặc neutral.

Mô hình hóa bài toán phân tích cảm xúc đánh giá sản phẩm



Hình 1. 1 Minh họa dữ liệu đánh giá sản phẩm trên sàn thương mại điện tử

1.3. Xử lý ngôn ngữ tự nhiên tiếng Việt

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) là lĩnh vực nghiên cứu các phương pháp giúp máy tính phân tích, biểu diễn và xử lý ngôn ngữ của con người. Trong đề tài này, NLP được sử dụng ở hai tầng: tầng chuẩn hóa dữ liệu review và tầng biểu diễn văn bản cho mô hình học máy hoặc học sâu. Nếu tiền xử lý không tốt, mô hình có thể học nhầm từ nhiễu, làm giảm độ chính xác khi triển khai trên dữ liệu thực tế.

Tiếng Việt có đặc điểm khác tiếng Anh khi một từ hoặc cụm từ có thể gồm nhiều âm tiết tách nhau bằng dấu cách như “giao hàng”, “sản phẩm”, “chăm sóc khách hàng”. Vì vậy, trong bài toán phân tích cảm xúc, việc tách từ và chuẩn hóa dữ liệu là bước quan trọng để mô hình hiểu đúng ngữ nghĩa.

Ngoài ra, dữ liệu review trên các sàn thương mại điện tử thường chứa từ viết tắt, teencode, emoji hoặc ký tự kéo dài như “sp”, “okela”, “đẹpppp”. Những yếu tố này vừa gây nhiễu vừa mang thông tin cảm xúc, nên cần được xử lý phù hợp thay vì loại bỏ hoàn toàn. Quy trình tiền xử lý được đề xuất gồm: loại bỏ dữ liệu trùng lặp, chuẩn hóa chữ thường, xử lý khoảng trắng, URL, ký tự đặc biệt, chuẩn hóa teencode và emoji, sau đó đưa dữ liệu về định dạng thống nhất. Với mô hình TF-IDF có thể thực hiện thêm bước tách từ và loại bỏ stopwords, trong khi mô hình PhoBERT yêu cầu quy trình tiền xử lý nhất quán giữa giai đoạn huấn luyện và dự đoán.

Nguồn dữ liệu dùng cho đề tài có thể kết hợp dữ liệu crawl thực tế và dữ liệu công khai. UIT-VSFC là bộ dữ liệu phản hồi sinh viên tiếng Việt cho bài toán phân

tích cảm xúc, có ích trong việc học biểu đạt cảm xúc tiếng Việt. Bên cạnh đó, các nghiên cứu về phân tích cảm xúc theo khía cạnh và hệ thống social listening cho tiếng Việt cung cấp thêm kinh nghiệm về cách khai thác ý kiến người dùng trong môi trường thực tế. Việc kết hợp nhiều nguồn giúp tập dữ liệu đa dạng hơn, nhưng cũng yêu cầu chuẩn hóa nhãn cẩn thận để tránh mâu thuẫn giữa các miền dữ liệu.



Hình 1. 2 Quy trình tiền xử lý dữ liệu đánh giá tiếng Việt

1.4. Học máy trong phân loại văn bản

Học máy là hướng tiếp cận cho phép mô hình học quy luật từ dữ liệu thay vì lập trình thủ công từng quy tắc. Với phân loại văn bản, quy trình cơ bản gồm hai bước: chuyển văn bản thành vector số và dùng thuật toán phân loại để ánh xạ vector đó sang nhãn cảm xúc. Cách tiếp cận này phù hợp để xây dựng mô hình baseline vì dễ triển khai, huấn luyện nhanh và giúp kiểm tra chất lượng dữ liệu trước khi dùng mô hình phức tạp hơn.

TF-IDF là kỹ thuật biểu diễn văn bản phổ biến trong các hệ thống phân loại truyền thống. Ý tưởng chính là một từ có giá trị phân biệt cao khi nó xuất hiện nhiều trong một văn bản nhưng không xuất hiện quá phổ biến trong toàn bộ tập dữ liệu. Trong bài toán review, các từ như “lỗi”, “thất vọng”, “nhanh”, “đẹp”, “ổn” thường mang tín hiệu cảm xúc mạnh. Sau khi vector hóa bằng TF-IDF, mỗi review được biểu diễn thành một vector thưa, trong đó mỗi chiều tương ứng với một từ hoặc cụm từ trong từ vựng.

SVM là một thuật toán phù hợp với dữ liệu văn bản vì có khả năng tìm siêu phẳng phân tách tốt trong không gian đặc trưng nhiều chiều [6]. Logistic Regression cũng thường được dùng làm baseline vì dễ giải thích và cho kết quả ổn định. Random

Forest có ưu điểm kết hợp nhiều cây quyết định để giảm phụ thuộc vào một mô hình đơn lẻ, tuy nhiên với dữ liệu văn bản thưa và số chiều lớn, hiệu quả của Random Forest có thể không luôn vượt SVM hoặc Logistic Regression.

1.5. Học sâu và mô hình tuần tự

Học sâu sử dụng mạng nơ-ron nhiều lớp để học đặc trưng dữ liệu tự động thay vì phụ thuộc vào đặc trưng thủ công. Trong xử lý ngôn ngữ tự nhiên, các từ thường được biểu diễn bằng embedding nhằm giúp mô hình hiểu được mối quan hệ ngữ nghĩa giữa các từ trong văn bản.

LSTM và GRU là các mô hình học sâu phổ biến dùng để xử lý dữ liệu chuỗi. LSTM có khả năng ghi nhớ thông tin quan trọng và loại bỏ thông tin không cần thiết thông qua các cổng xử lý, trong khi GRU là phiên bản đơn giản hơn nhưng vẫn đảm bảo hiệu quả học ngữ cảnh. So với TF-IDF, các mô hình này có ưu điểm là xem xét được thứ tự từ và ngữ cảnh câu, giúp xử lý tốt hơn các câu phủ định hoặc đánh giá dài.

Tuy nhiên, LSTM/GRU yêu cầu thời gian huấn luyện lớn hơn và cần nhiều dữ liệu để đạt hiệu quả cao. Trong đề tài, nhóm mô hình này được sử dụng như bước trung gian giữa các mô hình học máy truyền thống và mô hình tiền huấn luyện PhoBERT nhằm đánh giá sự cải thiện hiệu năng qua từng phương pháp.

1.6. Transformer, BERT, RoBERTa và PhoBERT

1.6.1. Kiến trúc Transformer

Transformer là kiến trúc học sâu được giới thiệu trong công trình “Attention Is All You Need” [8]. Điểm cốt lõi của Transformer là cơ chế self-attention, cho phép mỗi token trong câu tính toán mức độ liên quan với tất cả token còn lại. Nhờ đó, mô hình không cần đọc văn bản hoàn toàn tuần tự như LSTM mà vẫn có thể nắm bắt quan hệ ngữ cảnh ở khoảng cách xa. Đây là lý do Transformer trở thành nền tảng của nhiều mô hình ngôn ngữ hiện đại.

Trong bài toán phân tích cảm xúc, self-attention đặc biệt hữu ích với các câu có cấu trúc phức tạp. Ví dụ, ở câu “đóng gói đẹp nhưng máy chạy nóng”, mô hình cần hiểu rằng “đẹp” liên quan đến “đóng gói” còn “nóng” liên quan đến “máy”. Nếu chỉ đếm từ, mô hình có thể bị nhiễu giữa tín hiệu tích cực và tiêu cực. Cơ chế chú ý giúp mô hình phân bổ trọng số khác nhau cho từng phần của câu khi dự đoán nhãn tổng thể.


1.6.2. BERT và RoBERTa

BERT là mô hình ngôn ngữ tiền huấn luyện dựa trên Transformer encoder, học biểu diễn ngữ cảnh hai chiều cho văn bản [9]. Khác với các mô hình chỉ đọc từ trái sang phải, BERT sử dụng thông tin cả phía trước và phía sau để hiểu một token trong câu. Sau giai đoạn tiền huấn luyện trên tập văn bản lớn, BERT có thể được fine-tune cho nhiều nhiệm vụ như phân loại văn bản, trả lời câu hỏi hoặc nhận dạng thực thể.

RoBERTa là phiên bản tối ưu hóa mạnh hơn của BERT [10]. Mô hình thay đổi một số lựa chọn huấn luyện như bỏ nhiệm vụ Next Sentence Prediction, dùng dữ liệu

lớn hơn và chiến lược huấn luyện hiệu quả hơn. Các cải tiến này làm cho RoBERTa thường đạt kết quả tốt hơn BERT trên nhiều benchmark. PhoBERT được xây dựng dựa trên hướng tiếp cận RoBERTa nhưng chuyên biệt cho tiếng Việt, vì vậy phù hợp hơn so với dùng trực tiếp mô hình tiếng Anh cho dữ liệu review tiếng Việt.

Kiến trúc fine-tuning PhoBERT cho bài toán phân tích cảm xúc



Hình 1. 3 Kiến trúc fine-tuning PhoBERT cho bài toán phân tích cảm xúc

1.6.3. PhoBERT và lý do lựa chọn cho đề tài

PhoBERT là mô hình tiền huấn luyện cho tiếng Việt được công bố bởi Nguyen và cộng sự. Mô hình được huấn luyện trên lượng lớn văn bản tiếng Việt, nhờ đó học được nhiều đặc trưng ngữ pháp, từ vựng và ngữ nghĩa đặc thù của tiếng Việt. Trong các bài toán NLP tiếng Việt, PhoBERT thường là một lựa chọn mạnh vì giảm nhu cầu huấn luyện mô hình từ đầu và tận dụng được tri thức ngôn ngữ đã học trước đó.

Đối với đề tài này, PhoBERT phù hợp vì dữ liệu review có nhiều hiện tượng ngữ nghĩa phụ thuộc ngữ cảnh: phủ định, so sánh, khen chê lẫn lộn, từ viết tắt và sắc thái cảm xúc nhẹ. Mô hình được fine-tune bằng cách thêm lớp phân loại gồm ba đầu ra tương ứng negative, neutral và positive. Trong triển khai thực tế, có thể sử dụng thư viện HuggingFace Transformers để nạp tokenizer, nạp mô hình và huấn luyện AutoModelForSequenceClassification [11].

Fine-tuning khác với huấn luyện từ đầu. Khi fine-tune, mô hình đã có sẵn tri thức ngôn ngữ từ giai đoạn tiền huấn luyện, sau đó được điều chỉnh trên tập review của đề tài. Cách làm này tiết kiệm dữ liệu và thời gian hơn so với xây dựng mô hình ngôn ngữ mới. Tuy nhiên, PhoBERT vẫn cần dữ liệu gán nhãn đủ sạch, tỷ lệ train/validation/test hợp lý và cơ chế kiểm soát overfitting. Nếu dữ liệu huấn luyện lệch nhiều về nhãn positive, mô hình có thể đạt Accuracy cao nhưng nhận diện negative kém, nên F1-score và Confusion Matrix vẫn cần được phân tích kỹ.

Phiên bản mô hình đề xuất trong đồ án là `vinai/phobert-base-v2`. Độ dài đầu vào có thể đặt ở mức 256 token để cân bằng giữa khả năng giữ ngữ cảnh và chi phí tính toán. Trong quá trình huấn luyện, các tham số như learning rate, batch size, số epoch, weight decay và early stopping cần được ghi rõ trong Chương 3 để bảo đảm tính tái lập. Việc trình bày rõ cấu hình này giúp báo cáo có tính kỹ thuật và thuyết phục hơn khi bảo vệ.

Bảng 1.1. So sánh các hướng tiếp cận cho bài toán phân tích cảm xúc tiếng Việt

Hướng tiếp cận	Mô hình đại diện	Ưu điểm	Hạn chế	Vai trò trong đề tài
Học máy truyền thống	TF-IDF+Logistic Regression/SVM/Random Forest	Huấn luyện nhanh, dễ giải thích, phù hợp làm mốc so sánh	Khó hiểu thứ tự từ, phủ định và ngữ cảnh phức tạp	Baseline để kiểm tra dữ liệu và so sánh hiệu năng
Học sâu tuần tự	LSTM/GRU	Học được quan hệ thứ tự trong chuỗi, tốt hơn túi từ trong nhiều trường hợp	Cần nhiều dữ liệu hơn, dễ overfitting, khó nắm bắt ngữ cảnh xa	Mô hình trung gian để đánh giá lợi ích của biểu diễn tuần tự
Mô hình tiền huấn luyện	PhoBERT	Hiểu ngữ cảnh tiếng Việt tốt, tận dụng tri thức tiền huấn luyện	Cần GPU hoặc thời gian xử lý lớn hơn, cần tinh chỉnh tham số	Hướng chính để xây dựng bộ phân loại sentiment cho hệ thống

1.7. Thu thập dữ liệu từ website thương mại điện tử

Thu thập dữ liệu là bước nền tảng của hệ thống. Nguồn dữ liệu chính gồm các review từ sàn thương mại điện tử và các bộ dữ liệu công khai tiếng Việt. Với dữ liệu từ sàn, hệ thống cần lấy được nội dung bình luận, điểm rating, thời gian, tên sản, mã sản phẩm và các thông tin bổ sung nếu có. Những trường dữ liệu này giúp không chỉ huấn luyện mô hình mà còn phục vụ dashboard, thống kê theo thời gian và truy vấn bằng data assistant.

Việc crawl review từ các website thương mại điện tử có nhiều thách thức kỹ thuật. Nội dung review thường được tải động bằng JavaScript, không xuất hiện trực tiếp trong HTML ban đầu. Một số nền tảng sử dụng API nội bộ kèm token, cookie, tham số động hoặc cơ chế giới hạn tần suất truy cập. Vì vậy, hệ thống cần thiết kế crawler linh hoạt: ưu tiên gọi API nếu có thể, nhưng sẵn sàng dùng Playwright để điều khiển trình duyệt, theo dõi network response và lấy dữ liệu được trang tải về.

Để bảo đảm dữ liệu thu được có thể dùng thống nhất cho nhiều sản phẩm, đề tài chuẩn hóa review về một schema chung. Mỗi bản ghi nên gồm: review_id, product_id, platform, rating, content, created_at, variation, images, helpful_count và thông tin người dùng đã ẩn danh. Việc ẩn danh là cần thiết vì mục tiêu của hệ thống là phân tích xu hướng phản hồi, không phải nhận dạng cá nhân người mua. Cách tổ chức này cũng giúp hệ thống mở rộng thêm nguồn dữ liệu mới mà không phải thay đổi toàn bộ pipeline AI.

Một vấn đề cần trình bày khi bảo vệ là chất lượng dữ liệu quan trọng không kém số lượng dữ liệu. Nếu crawler lấy nhiều review trùng, review không có nội dung, bình luận spam hoặc dữ liệu sai mã hóa tiếng Việt, mô hình sẽ học sai. Do đó, sau khi thu thập cần có bước kiểm tra: loại trùng, loại mẫu rỗng, thống kê phân bố nhãn, kiểm tra độ dài câu, kiểm tra tỷ lệ rating theo lớp và lấy mẫu ngẫu nhiên để đọc thủ công. Các bước này giúp báo cáo tránh cảm giác chỉ liệt kê công nghệ mà thiếu quy trình khoa học.



Hình 1. 4 Quy trình thu thập và chuẩn hóa dữ liệu đánh giá sản phẩm

CHƯƠNG 2. PHƯƠNG PHÁP, MÔ HÌNH VÀ THIẾT KẾ HỆ THỐNG

2.1. Phân tích bài toán và mô hình hóa đầu vào - đầu ra

Đề tài tập trung vào bài toán phân tích cảm xúc đánh giá khách hàng trên các sàn thương mại điện tử bằng kỹ thuật xử lý ngôn ngữ tự nhiên và học máy. Mỗi dữ liệu đầu vào gồm nội dung review, số sao và thông tin liên quan đến sản phẩm, trong khi đầu ra là một trong ba nhãn cảm xúc: tích cực, trung lập hoặc tiêu cực. Cách tiếp cận này giúp người bán và doanh nghiệp hiểu rõ hơn mức độ hài lòng của khách hàng thay vì chỉ dựa vào số sao đánh giá.

Dữ liệu review thực tế có nhiều đặc điểm phức tạp như câu ngắn, viết tắt, thiếu dấu, teencode hoặc chứa nhiều ý kiến trong cùng một bình luận. Vì vậy, hệ thống cần có bước tiền xử lý phù hợp để chuẩn hóa dữ liệu và giữ lại các tín hiệu cảm xúc quan trọng trước khi đưa vào mô hình.

Trong đề tài, nhiều hướng tiếp cận được khảo sát gồm mô hình học máy truyền thống (TF-IDF + SVM), mô hình học sâu như LSTM/BiLSTM và mô hình ngôn ngữ tiên huấn luyện PhoBERT. Việc thử nghiệm nhiều phương pháp giúp đánh giá hiệu quả của từng mô hình và lựa chọn giải pháp phù hợp nhất cho dữ liệu tiếng Việt.

Nguồn dữ liệu được kết hợp từ review thu thập trên các sàn thương mại điện tử và các bộ dữ liệu tiếng Việt công khai như UIT-VSFC nhằm tăng tính đa dạng và cải thiện khả năng tổng quát của mô hình.

2.2. Các hướng nghiên cứu liên quan đến phân tích cảm xúc tiếng Việt

Phân tích cảm xúc tiếng Việt đã được tiếp cận theo nhiều hướng khác nhau, từ các mô hình học máy dựa trên đặc trưng thủ công đến các mô hình tiên huấn luyện có khả năng học biểu diễn ngữ cảnh. Với các bộ dữ liệu như UIT-VSFC, bài toán thường được mô hình hóa ở mức câu hoặc phản hồi, trong đó nhãn cảm xúc phản ánh thái độ tổng thể của người viết. Với các nghiên cứu gần hơn với dữ liệu sản phẩm như SA2SL/UIT-ViSFD, bài toán có thể được mở rộng sang phân tích theo khía cạnh, nơi một câu có thể chứa nhiều ý kiến khác nhau về nhiều thành phần của sản phẩm.

Đối với đề tài này, việc khảo sát related work không nhằm khẳng định một mô hình duy nhất là tối ưu trong mọi trường hợp. Thực tế, các nhóm phương pháp khác nhau giải quyết những vấn đề khác nhau. TF-IDF và SVM thường tạo ra baseline mạnh cho văn bản ngắn khi tín hiệu cảm xúc thể hiện qua từ khóa rõ ràng. LSTM và các biến thể tuần tự giúp mô hình quan tâm đến trật tự từ, nên có lợi khi câu có cấu trúc đảo chiều hoặc nhiều mệnh đề. Transformer và các mô hình như BERT, RoBERTa, PhoBERT lại tập trung vào biểu diễn ngữ cảnh hai chiều và khả năng fine-tune trên tác vụ cụ thể.

2.2.1. Nhóm phương pháp TF-IDF và bộ phân loại cổ điển

Trong các bài toán phân loại văn bản, hướng tiếp cận truyền thống thường bắt đầu bằng việc chuyển văn bản sang vector số. TF-IDF là một trong những phương pháp phổ biến vì nó kết hợp tần suất xuất hiện của từ trong văn bản với mức độ phân biệt của từ đó trên toàn bộ tập dữ liệu. Trực giác của TF-IDF tương đối dễ hiểu: một từ xuất hiện nhiều trong một review nhưng ít xuất hiện ở các review khác có thể mang thông tin phân loại cao hơn một từ quá phổ biến. Với dữ liệu thương mại điện tử, những từ như “lỗi”, “bê”, “nhanh”, “đẹp”, “hài lòng” có thể tạo ra tín hiệu mạnh cho mô hình baseline.

Sau bước biểu diễn, các bộ phân loại như Logistic Regression, SVM hoặc Random Forest có thể được huấn luyện để dự đoán nhãn cảm xúc. Trong đó, SVM đặc biệt phù hợp với dữ liệu văn bản vì vector TF-IDF thường có số chiều lớn và khá thưa; nguyên lý của SVM là tìm một siêu phẳng phân tách các lớp sao cho biên phân tách đạt mức tốt nhất trong không gian đặc trưng. Ưu điểm của nhóm mô hình này là thời gian huấn luyện nhanh, không yêu cầu GPU và kết quả dễ diễn giải hơn so với mô hình học sâu.

Tuy nhiên, hạn chế của TF-IDF và các bộ phân loại cổ điển là chúng không thật sự hiểu quan hệ ngữ cảnh. Câu “không tệ như mình nghĩ” và câu “tệ, không dùng được” đều chứa từ “tệ”, nhưng sắc thái khác nhau. Tương tự, câu “máy chạy êm nhưng pin xuống hơi nhanh” chứa cả tín hiệu tích cực và tiêu cực. Nếu chỉ dựa trên trọng số từ, mô hình dễ đánh giá sai khi từ khóa cảm xúc không phản ánh toàn bộ ý nghĩa câu. Đây là lý do nhóm phương pháp này được dùng như baseline khoa học, chứ không phải giải pháp cuối cùng duy nhất cho đề tài.

Trong báo cáo này, baseline không được xem là “mô hình yếu” để dễ vượt qua. Ngược lại, nó là bước kiểm tra bắt buộc: nếu dữ liệu, nhãn và quy trình đánh giá chưa ổn định, một mô hình mạnh như PhoBERT cũng có thể cho kết quả thiếu tin cậy. Baseline giúp phát hiện sớm các lỗi như nhãn bị lệch, dữ liệu trùng lặp giữa train và test, hoặc quy tắc tiền xử lý làm mất tín hiệu cảm xúc. Vì vậy, việc xây dựng TF-IDF + SVM là một phần của phương pháp thực nghiệm nghiêm túc.

2.2.2. Nhóm mô hình tuần tự: LSTM, BiLSTM và attention

Khác với TF-IDF, các mô hình LSTM và BiLSTM xử lý văn bản như một chuỗi có thứ tự, giúp mô hình hiểu được ngữ cảnh và mối liên hệ giữa các từ trong câu. LSTM sử dụng cơ chế cổng để ghi nhớ hoặc loại bỏ thông tin quan trọng, nhờ đó xử lý tốt hơn các câu dài và các trường hợp cảm xúc phụ thuộc vào ngữ cảnh phía sau. BiLSTM mở rộng LSTM bằng cách đọc văn bản theo cả hai chiều, giúp mô hình hiểu

tốt hơn các câu có cấu trúc chuyển ý như “nhưng”, “tuy nhiên”. Ví dụ, trong câu “sản phẩm đẹp nhưng giao hàng chậm”, mô hình có thể nhận biết đồng thời cả ý khen và ý chê để đưa ra dự đoán chính xác hơn.

Bên cạnh đó, cơ chế Attention cho phép mô hình tập trung vào các từ hoặc cụm từ quan trọng trong câu thay vì chỉ phụ thuộc vào trạng thái cuối của chuỗi. Điều này giúp cải thiện khả năng nhận diện cảm xúc trong các review có nhiều ý kiến khác nhau. Tuy nhiên, các mô hình tuần tự thường cần nhiều dữ liệu và thời gian huấn luyện hơn so với các mô hình truyền thống. Trong đề tài, LSTM/BiLSTM được sử dụng để đánh giá mức độ cải thiện khi học ngữ cảnh trước khi áp dụng mô hình Transformer như PhoBERT.

2.2.3. Mô hình Transformer và hướng tiền huấn luyện ngôn ngữ

Transformer đánh dấu sự thay đổi lớn trong xử lý ngôn ngữ tự nhiên vì không xử lý chuỗi theo từng bước tuần tự như RNN/LSTM mà dựa vào cơ chế self-attention. Với self-attention, mỗi token có thể tính toán mức liên quan với các token khác trong cùng câu. Điều này đặc biệt hữu ích cho dữ liệu review, nơi tín hiệu cảm xúc có thể nằm ở nhiều vị trí khác nhau. Ví dụ, trong câu “giá không rẻ nhưng chất lượng vải và đường may đều ổn”, cụm “không rẻ” không nhất thiết kéo toàn câu về tiêu cực nếu phần sau cung cấp đánh giá tích cực rõ hơn.

Trên nền Transformer, BERT giới thiệu hướng tiền huấn luyện mô hình ngôn ngữ hai chiều rồi fine-tune cho các tác vụ cụ thể. Thay vì huấn luyện một mô hình phân loại từ đầu, người dùng có thể tận dụng biểu diễn ngôn ngữ đã học từ lượng văn bản lớn và chỉ điều chỉnh mô hình trên tập dữ liệu của tác vụ. RoBERTa tiếp tục cải tiến quy trình tiền huấn luyện của BERT, trong đó có thay đổi về chiến lược huấn luyện và dữ liệu, giúp mô hình đạt kết quả tốt hơn trên nhiều benchmark.

PhoBERT kế thừa hướng RoBERTa nhưng được huấn luyện cho tiếng Việt, do đó có cơ sở phù hợp hơn với các tác vụ NLP tiếng Việt so với việc dùng trực tiếp mô hình đa ngữ trong mọi trường hợp. Với đề tài này, lợi thế của PhoBERT không chỉ nằm ở tên gọi “mô hình tiếng Việt”, mà ở khả năng học các mẫu ngữ cảnh đặc thù như từ ghép, dấu thanh, cách diễn đạt ngắn gọn và các cấu trúc câu phổ biến trong tiếng Việt. Thư viện Hugging Face Transformers hỗ trợ quy trình fine-tune các mô hình như PhoBERT theo dạng phân loại chuỗi, giúp việc triển khai mô hình nghiên cứu vào ứng dụng trở nên nhất quán hơn.

Bảng 2.1. So sánh khái quát các nhóm phương pháp phân tích cảm xúc

Phương pháp	Biểu diễn đầu vào	Ưu điểm	Hạn chế	Vai trò trong đề tài
-------------	-------------------	---------	---------	----------------------

TF-IDF + ML	Vector thưa theo từ/ngữ	Nhanh, dễ giải thích, ít tốn tài nguyên	Khó hiểu đảo nghĩa và ngữ cảnh nhiều mệnh đề	Baseline kiểm tra dữ liệu và mốc so sánh
LSTM/ BiLSTM	Chuỗi token/embedding	Giữ được trật tự từ, phù hợp câu có mệnh đề	Cần nhiều dữ liệu hơn, huấn luyện lâu hơn	Mốc trung gian giữa ML và Transformer
Transformer/ PhoBERT	Biểu diễn ngữ cảnh từ mô hình tiền huấn luyện	Hiểu ngữ cảnh tốt hơn, phù hợp tiếng Việt	Cần tài nguyên và pipeline nhất quán	Mô hình chính được kiểm chứng ở Chương 3

2.3. Nguồn dữ liệu và cách hình thành nhãn cảm xúc

Với bài toán sentiment, lỗi dữ liệu thường kéo theo lỗi mô hình: review trùng có thể làm đánh giá quá lạc quan, nhãn không nhất quán làm mô hình học sai, còn dữ liệu quá sạch lại không phản ánh cách người mua thật sự viết trên sàn TMĐT. Trong phạm vi đề tài, dữ liệu không được xem đơn thuần là tập câu đưa vào mô hình, mà là phản hồi gắn với bối cảnh mua hàng cụ thể. Một review trên sàn thương mại điện tử thường đi kèm số sao, thời điểm tạo, tên sản phẩm, biến thể sản phẩm và đôi khi có hình ảnh. Những thông tin này không phải lúc nào cũng được đưa trực tiếp vào mô hình văn bản, nhưng có giá trị trong quá trình làm sạch, kiểm tra nhãn và phân tích lỗi.

Nguồn dữ liệu thứ nhất là các bộ dữ liệu tiếng Việt công khai. UIT-VSFC là bộ dữ liệu phản hồi sinh viên tiếng Việt đã được sử dụng cho bài toán phân tích cảm xúc. Ưu điểm của nguồn này là có nhãn tương đối rõ, câu tiếng Việt tự nhiên và phù hợp để kiểm tra pipeline phân loại văn bản. Hạn chế là miền dữ liệu thuộc giáo dục, trong đó cách biểu đạt cảm xúc khác với review mua hàng. Ví dụ, một phản hồi sinh viên có thể nói về giảng viên, môn học hoặc cơ sở vật chất, trong khi review thương mại điện tử lại nói về chất liệu, giao hàng, đóng gói, giá cả và trải nghiệm sử dụng sản phẩm.

Nguồn dữ liệu thứ hai là các nghiên cứu và tập dữ liệu gần hơn với miền sản phẩm như SA2SL/UIT-ViSFD. Các nguồn này có giá trị vì nhiều câu chứa ý kiến về sản phẩm hoặc khía cạnh cụ thể của sản phẩm. Tuy nhiên, nếu dữ liệu ở dạng aspect-based sentiment analysis, một câu có thể có nhiều nhãn theo nhiều khía cạnh. Chẳng hạn, cùng một câu có thể tích cực về màn hình nhưng tiêu cực về pin. Khi chuyển sang bài toán phân loại cảm xúc toàn câu, cần có quy tắc chuyển đổi rõ ràng để tránh làm nhãn trở nên mâu thuẫn.

Nguồn dữ liệu thứ ba là review tự thu thập từ Shopee, Lazada và Tiki. Khác với dữ liệu công khai đã qua chuẩn hóa, dữ liệu crawl phản ánh trực tiếp cách người mua

viết sau khi nhận hàng. Ở giai đoạn kiểm tra dữ liệu ban đầu, nhóm gặp khá nhiều review rỗng, review chỉ có biểu tượng cảm xúc, review lặp lại do cùng một sản phẩm được tải ở nhiều trang, và các câu rất ngắn như “ok”, “ồ”, “hàng đẹp”, “shop giao nhanh”. Những bản ghi này không nên bị xóa toàn bộ một cách máy móc, vì trong bối cảnh thương mại điện tử, các cụm ngắn như “ồ” hoặc “hàng đẹp” vẫn là tín hiệu cảm xúc rõ.

Sự không nhất quán giữa rating và nội dung review là điểm cần xử lý cẩn thận khi hình thành nhãn. Có trường hợp người dùng vẫn cho 5 sao vì sản phẩm dùng được nhưng trong nội dung lại phàn nàn về vận chuyển: “máy chạy ồn, giao hơi lâu, hộp bị móp”. Ngược lại, một đánh giá 3 sao chưa chắc đã tiêu cực hoàn toàn, chẳng hạn “mới nhận hàng, chưa dùng lâu, đóng gói tạm ổn”. Vì vậy, rating chỉ nên được xem là tín hiệu hỗ trợ. Khi nội dung văn bản chứa cảm xúc rõ ràng, nhãn cần ưu tiên ý nghĩa của review; khi nội dung quá ngắn hoặc mơ hồ, rating và bối cảnh sản phẩm mới được dùng để hỗ trợ quyết định.

Chiến lược gán nhãn của đề tài được xây dựng theo nguyên tắc ưu tiên nội dung văn bản, sau đó mới tham chiếu rating. Với dữ liệu review có nội dung rõ ràng, nhãn được xác định dựa trên sắc thái tổng thể của bình luận. Với review quá ngắn hoặc mơ hồ, rating có thể hỗ trợ phân loại sơ bộ nhưng cần được đánh dấu để kiểm tra khi phân tích lỗi. Với các câu chứa cảm xúc pha trộn, quy tắc cần nhất quán: nếu bình luận có một lỗi nghiêm trọng ảnh hưởng trực tiếp trải nghiệm sản phẩm, nhãn có thể nghiêng về tiêu cực; nếu chỉ có một điểm trừ nhẹ nhưng đánh giá chung vẫn hài lòng, nhãn có thể là trung lập hoặc tích cực tùy mức độ.

Để bảo đảm tính tái lập, mỗi bản ghi sau chuẩn hóa nên có cấu trúc thống nhất gồm mã review, mã sản phẩm, tên sản phẩm, nền tảng, rating, nội dung gốc, nội dung sau làm sạch, thời điểm tạo, nhãn sentiment và nguồn dữ liệu. Việc lưu cả nội dung gốc lẫn nội dung đã xử lý giúp người thực hiện có thể quay lại kiểm tra khi phát hiện mô hình dự đoán sai. Cách tổ chức này cũng giúp dashboard và data assistant không bị tách khỏi dữ liệu gốc trong quá trình triển khai hệ thống.

Bảng 2.2. Đặc điểm các nguồn dữ liệu sử dụng trong đề tài

Nguồn	Miền dữ liệu	Kiểu nhãn	Ưu điểm	Hạn chế	Vai trò
UIT-VSFC	Phản hồi sinh viên tiếng Việt	Sentiment mức câu/phản hồi	Nhãn rõ, câu tiếng Việt tự nhiên	Khác miền thương mại điện tử	Kiểm tra pipeline và bổ sung biểu đạt tiếng Việt
SA2SL/UIT-	Sản	Có yếu tố	Gần miền	Cần	Tham

ViSFD	phẩm/smartphone , social listening	aspect- based	sản phẩm hơn	chuyển đổi nếu dùng cho nhân toàn câu	khảo chiến lược dữ liệu và nhãn
Review crawl TMĐT	Shopee, Lazada, Tiki	Nhãn suy luận/kiểm tra từ content và rating	Gần môi trường triển khai thật	Nhiều nhiều, dễ mâu thuẫn rating- content	Nguồn dữ liệu chính để đánh giá thực tế


Bảng 2.3. Quy tắc gán nhãn sentiment sử dụng trong đề tài

Trường hợp	Cách xử lý nhãn	Ví dụ minh họa	Ghi chú
Nội dung thể hiện cảm xúc rõ	Ưu tiên nội dung văn bản	“hàng lỗi, ko giống hình” -> negative; “đóng gói kỹ, giao nhANH” -> positive	Rating chỉ dùng để đối chiếu
Review rất ngắn nhưng có tín hiệu	Giữ lại nếu vẫn thể hiện thái độ	“ok”, “ổn”, “hàng đẹp”, “tệ”	Không xóa cơ học theo độ dài
Review vô nghĩa hoặc thiếu nội dung	Loại khỏi tập huấn luyện	“.....”, chỉ emoji, nội dung bị lỗi render	Có thể vẫn lưu thô để kiểm tra crawler
Rating mâu thuẫn với nội dung	Đọc lại, ưu tiên nội dung nếu rõ ràng	5 sao nhưng viết “shop giao thiếu phụ kiện”	Đưa vào nhóm cần rà thủ công
Câu pha trộn nhiều cảm xúc	Gán theo ý chính; nếu cân bằng thì neutral	“áo đẹp nhưng vải hơi mỏng”	Tránh ép nhãn quá cực đoan
Dữ liệu ABSA nhiều aspect	Majority vote hoặc loại mẫu quá mâu thuẫn	Camera positive, pin negative trong cùng câu	Không gộp nhãn máy móc

Bảng 2.4. Các thống kê dữ liệu cần báo cáo sau khi làm sạch

Chỉ tiêu	Cách tính	Vị trí trình bày	Ý nghĩa khi bảo vệ
Số review thô	Đếm toàn bộ bản ghi crawler thu được	Chương 3	Cho biết quy mô dữ liệu ban đầu
Số review sau lọc	Loại bản ghi rỗng, trùng, lỗi render	Chương 3	Phản ánh chất lượng dữ liệu sử dụng thật
Số sản phẩm và số sán	Thống kê theo product_id và platform	Chương 3	Tránh dữ liệu lệch về một sản phẩm
Tỷ lệ nhãn	Tính trên tập sau	Chương 3	Kiểm tra mất cân

positive/neutral/negative	gán nhãn		bảng dữ liệu
Độ dài trung bình review	Số token/ký tự trung bình sau làm sạch	Chương 3	Hỗ trợ chọn max_length cho mô hình
Tỷ lệ review bị loại	Review bị loại / review thô	Chương 3	Đánh giá mức nhiễu của dữ liệu crawl



Hình 2. 1 Quy trình hình thành dữ liệu và nhãn cảm xúc

2.4. Tiền xử lý tiếng Việt và biểu diễn đầu vào

Tiền xử lý dữ liệu trong đề tài được thiết kế theo hướng giữ lại tín hiệu cảm xúc nhưng loại bỏ các nhiễu làm mô hình học sai. Kinh nghiệm từ dữ liệu thử nghiệm cho thấy nếu làm sạch quá mạnh, nhiều câu review sẽ mất sắc thái thật của người mua; nhưng nếu giữ nguyên hoàn toàn, mô hình lại phải xử lý quá nhiều biến thể viết tắt, ký tự kéo dài và lỗi gõ. Vì vậy, pipeline tiền xử lý được xây dựng theo nguyên tắc vừa đủ: sửa những lỗi làm lệch biểu diễn, nhưng không biến review thành văn bản báo chí quá chuẩn.

Bước đầu tiên là loại bỏ bản ghi rỗng, bản ghi chỉ chứa ký tự vô nghĩa, bản ghi trùng lặp và các dòng có dấu hiệu lỗi thu thập. Ví dụ, một review chỉ gồm chuỗi “.....” hoặc một đoạn HTML bị lỗi không nên được đưa vào huấn luyện. Sau đó, văn bản được chuẩn hóa chữ thường, chuẩn hóa khoảng trắng, thống nhất một số ký tự

Unicode và xử lý các lỗi gõ phím phổ biến. Các bước này giúp giảm số lượng biến thể bề mặt của cùng một câu, qua đó làm cho tập dữ liệu ổn định hơn.

Với các biểu hiện phi chuẩn, đề tài xử lý có chọn lọc thay vì xóa bỏ. Chẳng hạn, “áo xìnhhh, vải mát ghêee” được chuẩn hóa thành “áo xinh, vải mát ghê” để giảm ký tự kéo dài nhưng vẫn giữ sắc thái khen. Câu “ko giống hình lắm, được cái shop gói cẩn thận” được chuyển “ko” thành “không” nhưng giữ cấu trúc đối lập giữa phản nản và khen. Một review kiểu “pin tụt nhanh vl, sạc thì ok” cần được giữ lại các cụm chính để mô hình nhận ra cảm xúc tiêu cực về pin và đánh giá nhẹ tích cực về sạc.


Một điểm cần lưu ý là không nên đưa mọi câu về dạng quá sạch. Review thật thường có giọng nói đời thường, và chính giọng đó giúp mô hình nhận diện thái độ người dùng. Ví dụ, câu “hoi thất vọng xíu, tưởng màu đậm hơn” nhẹ hơn câu “sản phẩm quá tệ, không dùng được”, mặc dù cả hai đều có xu hướng tiêu cực. Nếu bỏ hết các từ như “hoi”, “xíu”, “tưởng”, mô hình có thể đánh giá sai cường độ cảm xúc.

Đối với pipeline TF-IDF + SVM, tiền xử lý có thể mạnh hơn vì mô hình dựa nhiều vào đặc trưng từ. Văn bản có thể được tách từ, loại bỏ một số stopwords ít mang thông tin cảm xúc và chuẩn hóa từ đồng nghĩa thông dụng. Tuy vậy, việc loại stopwords phải thận trọng: các từ phủ định như “không”, “chưa”, “chẳng” không được loại bỏ vì chúng có thể đảo ngược ý nghĩa cảm xúc. Câu “không lỗi” khác hoàn toàn với “lỗi”, nên một danh sách stopwords dùng chung cho mọi tác vụ có thể gây hại cho bài toán sentiment.

Đối với PhoBERT, yêu cầu quan trọng hơn là tính nhất quán giữa giai đoạn huấn luyện và suy luận. PhoBERT là mô hình tiền huấn luyện tiếng Việt dựa trên hướng RoBERTa, và khi triển khai qua Hugging Face Transformers, dữ liệu đầu vào được token hóa theo tokenizer tương ứng. Nếu dữ liệu huấn luyện được xử lý theo một cách nhưng dữ liệu khi dự đoán trong hệ thống web lại xử lý theo cách khác, mô hình có thể nhận đầu vào lệch phân phối. Vì vậy, các hàm chuẩn hóa phải được đóng gói dùng chung cho cả notebook huấn luyện và backend inference.

Một số ví dụ được dùng trong quá trình rà dữ liệu cho thấy sự khác nhau giữa chuẩn hóa kỹ thuật và chuẩn hóa ngữ nghĩa. Câu “ốp xài đc, lỗ camera hơi lệch” chỉ nên chuẩn hóa “đc” thành “được”, không nên loại cụm “hơi lệch” vì đây là tín hiệu phản nản chính. Câu “giao nhanh, hộp móp nhẹ, sp chưa test” nên được giữ cả ba phần để mô hình hoặc người gán nhãn thấy đây là đánh giá thận trọng, chưa chắc tích cực. Câu “mua lần 2 rồi, lần này shop giao thiếu dây” có yếu tố hài lòng trong quá khứ nhưng vấn đề hiện tại lại mang sắc thái tiêu cực.

Như vậy, tiền xử lý trong đề tài là một quyết định phương pháp gắn với dữ liệu cụ thể. Pipeline phải làm cho dữ liệu đủ sạch để mô hình học được, nhưng vẫn giữ lại những dấu hiệu mà người mua dùng để thể hiện cảm xúc. Các quy tắc chuẩn hóa được lưu cùng mã nguồn để quá trình huấn luyện, đánh giá và suy luận trong hệ thống web sử dụng cùng một cách xử lý đầu vào.



Hình 2. 2 Pipeline tiền xử lý review tiếng Việt

Hình 2.2 minh họa nguyên tắc tiền xử lý “vừa đủ”: chuẩn hóa các biến thể gây nhiễu như teen code, ký tự kéo dài và emoji, nhưng vẫn giữ lại từ phủ định, từ chuyển ý và các tín hiệu cảm xúc ngấm trong review. Đây là điểm quan trọng để mô hình không mất sắc thái tự nhiên của dữ liệu thương mại điện tử.

2.5. Baseline TF-IDF + SVM và vai trò kiểm chứng dữ liệu

Baseline TF-IDF + SVM được xây dựng trước hết để kiểm chứng chất lượng dữ liệu và quy trình đánh giá. Trong nhiều đề án sử dụng mô hình Transformer, baseline thường bị xem nhẹ vì không phải mô hình hiện đại. Tuy nhiên, với một bài toán phân loại văn bản, nếu baseline đơn giản đã hoạt động rất kém thì cần xem lại dữ liệu, nhãn và cách chia tập trước khi kết luận rằng cần mô hình phức tạp hơn. Ngược lại, nếu baseline đạt mức hợp lý, việc thử PhoBERT mới có ý nghĩa vì có mốc so sánh cụ thể.

TF-IDF biểu diễn văn bản bằng cách đánh trọng số từ dựa trên tần suất trong từng văn bản và mức độ xuất hiện trên toàn bộ tập dữ liệu. Với review thương mại điện tử, cách biểu diễn này nắm bắt tốt các tín hiệu cảm xúc trực tiếp. Các review như “hàng lỗi, không dùng được”, “đóng gói cẩn thận, giao nhanh”, hoặc “chất lượng tạm ổn so với giá” thường có từ khóa đủ rõ để baseline đưa ra dự đoán hợp lý. Khi kết hợp

với SVM, mô hình có thể tìm biên phân tách trong không gian đặc trưng thưa có số chiều lớn.

SVM phù hợp với dữ liệu văn bản không chỉ vì khả năng xử lý số chiều cao, mà còn vì nó hoạt động tốt khi mỗi văn bản chỉ kích hoạt một phần nhỏ trong toàn bộ từ vựng. Trong dữ liệu review, không phải review nào cũng nói về cùng một khía cạnh; có câu nói về giao hàng, có câu nói về chất liệu, có câu nói về pin hoặc màu sắc. Vector TF-IDF thưa phản ánh đúng đặc điểm này. Một mô hình tuyến tính như SVM có thể học được rằng một số từ/cụm từ làm tăng xác suất nhãn tiêu cực hoặc tích cực mà không cần huấn luyện mạng nơ-ron sâu.

Tuy nhiên, baseline cũng có những điểm dễ thất bại. Một lỗi thường gặp là nhầm lẫn trong câu có phủ định hoặc chuyển ý. Ví dụ, “không quá xuất sắc nhưng dùng ổn” không nên bị hiểu là tiêu cực chỉ vì có “không” và “không quá”. Ngược lại, “đẹp thì đẹp nhưng mới dùng đã bung chỉ” có phần đầu tích cực nhưng trọng tâm trải nghiệm lại nghiêng về tiêu cực. Baseline dựa trên từ khóa có thể thiếu khả năng xác định về nào quan trọng hơn trong nhận định cuối cùng.

Ngoài SVM, đề tài có thể sử dụng Logistic Regression hoặc Random Forest như mô hình đối chiếu phụ. Logistic Regression cho phép quan sát trọng số đặc trưng một cách trực quan hơn, trong khi Random Forest kiểm tra xem mô hình phi tuyến dựa trên cây có cải thiện gì trên đặc trưng TF-IDF hay không. Tuy nhiên, các mô hình phụ này không thay thế vai trò chính của baseline SVM mà chỉ giúp đánh giá tính ổn định của kết quả trên nhóm học máy truyền thống.

Ở bước thiết kế thực nghiệm, baseline không được đưa vào chỉ để tăng số lượng mô hình so sánh. Nó giúp trả lời ba câu hỏi phương pháp: dữ liệu đã đủ sạch chưa, nhãn có nhất quán không, và mô hình ngữ cảnh có thật sự tạo ra lợi ích so với mô hình túi từ hay không. Nếu PhoBERT vượt baseline ở các trường hợp câu pha trộn, câu có phủ định hoặc câu nhiều mệnh đề, sự cải thiện đó mới có thể được giải thích bằng khả năng biểu diễn ngữ cảnh thay vì chỉ bằng việc mô hình lớn hơn.

2.6. Cơ sở chọn PhoBERT cho dữ liệu review tiếng Việt

BERT là mô hình ngôn ngữ tiền huấn luyện dựa trên kiến trúc Transformer, được sử dụng rộng rãi trong các bài toán NLP như phân loại văn bản và phân tích cảm xúc. RoBERTa là phiên bản cải tiến của BERT với quy trình huấn luyện tối ưu hơn, từ đó tạo ra khả năng biểu diễn ngôn ngữ hiệu quả hơn. PhoBERT được phát triển dựa trên kiến trúc RoBERTa và được huấn luyện riêng cho tiếng Việt, nên phù hợp hơn với các bài toán xử lý ngôn ngữ tiếng Việt. Tiếng Việt có nhiều đặc điểm phức tạp như từ nhiều âm tiết, dấu thanh, từ viết tắt, teencode và cách diễn đạt không chuẩn trong

review thương mại điện tử. Nhờ được tiền huấn luyện trên dữ liệu tiếng Việt, PhoBERT có khả năng biểu diễn ngữ nghĩa và ngữ cảnh tốt hơn so với các mô hình đa ngữ thông thường.

Trong đề tài, PhoBERT được sử dụng làm mô hình chính cho bài toán phân tích cảm xúc review sản phẩm. Quá trình triển khai được thực hiện thông qua thư viện Hugging Face Transformers để hỗ trợ tokenizer, huấn luyện, đánh giá và lưu mô hình phục vụ tích hợp vào hệ thống web.

Bảng 2.5. So sánh các lựa chọn mô hình trong thiết kế thực nghiệm

Mô hình	Đầu vào	Điểm mạnh	Rủi ro/hạn chế	Câu hỏi cần kiểm chứng
TF-IDF + SVM	Văn bản đã làm sạch, vector TF-IDF	Nhanh, rõ ràng, phù hợp baseline	Yếu với phủ định và ngữ cảnh đối lập	Baseline có đủ mạnh để làm mốc không?
LSTM/BiLSTM	Chuỗi token/embedding	Học được thứ tự từ	Cần dữ liệu, nhạy cấu hình	Trật tự từ cải thiện bao nhiêu so với TF-IDF?
PhoBERT	Token hóa bằng tokenizer PhoBERT	Biểu diễn ngữ cảnh tiếng Việt tốt hơn	Tốn tài nguyên, cần pipeline ổn định	Mô hình tiền huấn luyện có cải thiện trên review TMĐT không?

2.8. Chỉ số đánh giá và quy trình thực nghiệm

Đánh giá mô hình phân tích cảm xúc cần nhiều hơn một chỉ số duy nhất. Accuracy cho biết tỷ lệ dự đoán đúng trên toàn bộ tập kiểm tra, nhưng chỉ số này có thể gây hiểu nhầm khi dữ liệu mất cân bằng. Trong review thương mại điện tử, nhãn tích cực thường có xu hướng xuất hiện nhiều hơn vì người mua hài lòng dễ để lại đánh giá ngắn như “tốt”, “ok”, “đẹp”. Nếu mô hình dự đoán thiên về lớp tích cực, Accuracy có thể cao nhưng khả năng phát hiện đánh giá tiêu cực lại thấp. Vì vậy, đề tài sử dụng thêm Precision, Recall, F1-score và Confusion Matrix.

Precision của một lớp đo tỷ lệ dự đoán đúng trong số các mẫu mà mô hình gán vào lớp đó. Recall đo tỷ lệ mẫu thật thuộc lớp đó được mô hình phát hiện đúng. F1-score là trung bình điều hòa của Precision và Recall, phù hợp khi cần cân bằng giữa việc dự đoán đúng và không bỏ sót mẫu. Với bài toán ba nhãn, Macro-F1 tính trung bình F1 của các lớp với trọng số bằng nhau, do đó phản ánh tốt hơn hiệu năng trên các lớp ít dữ liệu. Weighted-F1 tính trung bình có xét đến số lượng mẫu mỗi lớp, nên gần hơn với hiệu năng chung trên phân bố dữ liệu thực tế.

Confusion Matrix được dùng để phân tích mô hình nhằm giữa các lớp nào. Ví dụ, nếu nhiều mẫu tiêu cực bị dự đoán thành trung lập, có thể dữ liệu chứa nhiều câu phản nản nhẹ hoặc mô hình chưa học tốt các tín hiệu tiêu cực không trực tiếp. Nếu nhiều mẫu trung lập bị dự đoán thành tích cực, có thể quy tắc gán nhãn giữa neutral và positive chưa rõ ràng. Phân tích ma trận nhằm lần giúp cải thiện dữ liệu và mô hình có mục tiêu hơn so với việc chỉ nhìn vào một con số Accuracy.

Protocol thực nghiệm của đề tài cần bảo đảm công bằng giữa các mô hình. Tất cả mô hình phải dùng cùng tập train, validation và test; mọi bước làm sạch dữ liệu phải được áp dụng nhất quán; và tập test không được dùng để chọn tham số. Tập train dùng để huấn luyện, tập validation dùng để điều chỉnh tham số hoặc chọn checkpoint, còn tập test chỉ dùng cho đánh giá cuối cùng. Nếu có cross-validation cho baseline, cách chia và cách báo cáo cần được mô tả rõ để tránh so sánh lệch.

Bên cạnh các chỉ số phân loại, đề tài cũng cần ghi nhận thời gian huấn luyện và thời gian suy luận. Một mô hình có F1 cao nhưng latency quá lớn có thể gây khó khăn khi tích hợp vào hệ thống phân tích hàng loạt review. Với dashboard, thời gian dự đoán không chỉ ảnh hưởng trải nghiệm người dùng mà còn ảnh hưởng khả năng cập nhật dữ liệu khi crawler thu về nhiều review cùng lúc. Vì vậy, tiêu chí so sánh không chỉ gồm chất lượng dự đoán mà còn gồm chi phí tính toán và khả năng triển khai.

Các công thức đánh giá được trình bày dưới dạng ký hiệu để thống nhất cách đọc kết quả ở Chương 3. Với bài toán nhiều lớp, các chỉ số được tính riêng cho từng lớp cảm xúc rồi tổng hợp theo macro hoặc weighted tùy mục tiêu so sánh.

$$Accuracy = \frac{N_{correct}}{N_c}$$

$$Precision_c = \frac{TP_c}{TP_c + FP_c}$$

$$Recall_c = \frac{TP_c}{TP_c + FN_c}$$

$$F1_c = \frac{2 \times Precision_c \times Recall_c}{Precision_c + Recall_c}$$

$$Macro-F1 = \frac{1}{C} \sum_{c=1}^C F1_c$$

$$Weighted-F1 = \sum_{c=1}^C \frac{n_c}{N} F1_c$$

Trong đó, c là chỉ số lớp cảm xúc; C là số lớp; n_c là số mẫu thuộc lớp c ; N là tổng số mẫu. TP_c , FP_c và FN_c lần lượt là số mẫu dự đoán đúng của lớp c , số mẫu bị dự đoán nhầm vào lớp c và số mẫu của lớp c bị bỏ sót. Cách viết này sẽ được dùng thống nhất khi đọc bảng kết quả ở Chương 3.

Sau khi có kết quả, error analysis là bước bắt buộc. Các mẫu dự đoán sai sẽ được đọc lại và phân nhóm theo nguyên nhân: câu có cảm xúc pha trộn, câu quá ngắn, nội dung mâu thuẫn rating, từ lóng chưa có trong dữ liệu, hoặc lỗi gán nhãn. Bước này giúp phần kết luận không chỉ nói mô hình nào cao hơn mà còn giải thích vì sao mô hình sai và cần cải thiện ở đâu. Đây là cơ sở để đề xuất hướng phát triển trong phần cuối báo cáo.

Bảng 2.6. Các chỉ số đánh giá sử dụng trong đề tài

Chỉ số	Ý nghĩa	Khi nên dùng	Hạn chế
Accuracy	Tỷ lệ dự đoán đúng trên tổng mẫu	Đánh giá tổng quan khi dữ liệu cân bằng	Dễ gây hiểu nhầm nếu lệch nhãn
Precision	Độ đúng trong các mẫu được dự đoán vào một lớp	Khi cần giảm dự đoán sai dương	Không phản ánh mẫu bị bỏ sót
Recall	Khả năng phát hiện đúng mẫu thật của một lớp	Khi cần không bỏ sót review tiêu cực	Có thể tăng bằng cách dự đoán rộng
Macro-F1	F1 trung bình đều giữa các lớp	Khi dữ liệu mất cân bằng	Nhạy với lớp có rất ít mẫu
Weighted-F1	F1 trung bình theo số mẫu từng lớp	Khi muốn phản ánh phân bố thật	Có thể che khuất lớp thiểu số
Confusion Matrix	Bảng nhầm lẫn giữa nhãn thật và nhãn dự đoán	Phân tích lỗi	Cần đọc kèm ví dụ cụ thể
Latency	Thời gian suy luận	Đánh giá khả năng triển khai	Phụ thuộc phần cứng và batch size

2.9. Thiết kế hệ thống tích hợp crawler, mô hình và dashboard

Hệ thống của đề tài được thiết kế theo một luồng dữ liệu khép kín, trong đó mỗi thành phần tạo ra dữ liệu có thể kiểm tra lại ở bước sau. Phương án triển khai được chốt cho bản prototype là FastAPI ở tầng backend, MongoDB ở tầng lưu trữ, ReactJS ở tầng dashboard và PhoBERT ở tầng phân tích cảm xúc. Người dùng cung cấp URL sản phẩm; crawler thu review, rating và thời điểm tạo; dữ liệu thô được lưu lại trước khi chuẩn hóa để có thể đối chiếu khi nhãn dự đoán gây nghi ngờ. Sau đó, service mô hình xử lý nội dung review và trả về nhãn cảm xúc, confidence và xác suất từng lớp.

Cách tổ chức này giúp tránh tình trạng mỗi thành phần xử lý một phiên bản dữ liệu khác nhau. Nếu dashboard chỉ đọc dữ liệu đã tổng hợp mà không liên kết với review gốc, người dùng khó kiểm tra vì sao một sản phẩm có tỷ lệ tiêu cực cao. Ngược

lại, nếu hệ thống lưu review gốc, nhãn dự đoán, confidence và thời điểm phân tích, người dùng có thể truy ngược từ biểu đồ đến từng bình luận cụ thể. Điều này hữu ích khi cần giải thích một kết quả bất thường hoặc khi mô hình dự đoán sai trên các review có ngữ cảnh phức tạp.

Thành phần crawler được thiết kế để xử lý sự khác biệt giữa các sản phẩm. Với các trang có nội dung render động, Playwright là lựa chọn chính vì có thể điều khiển trình duyệt, theo dõi network request và lấy dữ liệu khi review được tải bằng JavaScript. Với những endpoint có thể truy cập trực tiếp, requests hoặc httpx được dùng để giảm thời gian tải trang. Trong quá trình thử, nhóm ưu tiên lưu cả dữ liệu thô vì cấu trúc trang thương mại điện tử có thể thay đổi, nếu chỉ lưu dữ liệu sau xử lý thì rất khó truy nguyên lỗi crawl.


Mô hình sentiment không nên được gọi như một đoạn mã rời trong từng endpoint. Thay vào đó, backend nên có một service riêng chịu trách nhiệm nạp tokenizer, nạp model, chuẩn hóa input, chạy suy luận và trả về label, confidence, probabilities. Với mô hình PhoBERT triển khai qua Hugging Face Transformers, việc giữ tokenizer và model trong bộ nhớ giúp giảm thời gian xử lý so với nạp lại mô hình cho mỗi request. Đối với batch review, service có thể gom nhiều câu vào một lần suy luận để giảm chi phí.

Dashboard được xây dựng bằng ReactJS để tách rõ phần giao diện khỏi backend API. Các biểu đồ cần thiết gồm phân bố sentiment theo sản phẩm, xu hướng sentiment theo thời gian, tỷ lệ review tiêu cực, rating trung bình, danh sách review có confidence thấp và các cụm từ thường xuất hiện trong review tiêu cực. Trong bối cảnh bảo vệ prototype, ReactJS giúp mô phỏng gần hơn một ứng dụng web thật so với việc chỉ trình bày kết quả trong notebook.


Data assistant trong đề tài được mô tả là trợ lý truy vấn dữ liệu, không phải chatbot trò chuyện tự do. Thành phần này chỉ trả lời các câu hỏi có thể truy ngược về dữ liệu review đã lưu. Ví dụ, nếu người dùng hỏi ‘sản phẩm nào có nhiều phản hồi tiêu cực nhất?’, hệ thống phải truy vấn MongoDB, trả về tên sản phẩm, số lượng review tiêu cực và một số review minh họa. Nhóm không thiết kế chatbot trả lời tự do về mọi chủ đề để tránh tạo nhận định không có dữ liệu kiểm chứng. Cách giới hạn này làm hệ thống dễ kiểm soát hơn, vì câu trả lời luôn có thể truy ngược về bản ghi review cụ thể thay vì chỉ dựa vào sinh văn bản tự do.

Luồng dữ liệu tổng thể của hệ thống được mô tả như Hình 2.3. Trong luồng này, mỗi bước đều tạo ra dữ liệu trung gian có thể kiểm tra lại: dữ liệu thô từ crawler, dữ liệu sau tiền xử lý, kết quả dự đoán của mô hình và dữ liệu tổng hợp cho dashboard. Việc lưu các trạng thái trung gian giúp hệ thống dễ debug hơn, đồng thời phù hợp với

yêu cầu nghiên cứu vì người thực hiện có thể phân tích nguyên nhân sai số ở từng giai đoạn.



Hình 2. 3 Luồng dữ liệu tổng thể của hệ thống



Hình 2. 4 Pipeline huấn luyện và triển khai mô hình sentiment

Các rủi ro kỹ thuật của hệ thống được nhận diện ngay trong thiết kế. Crawler có thể gặp chống bot, thay đổi cấu trúc trang hoặc timeout; vì vậy cần có log và lưu dữ liệu thô. Mô hình PhoBERT có thể có latency cao khi xử lý nhiều review liên tiếp; vì vậy backend cần hỗ trợ batch prediction thay vì gọi từng câu riêng lẻ. Dashboard có thể gây hiểu nhầm nếu số review quá ít, nên khi hiển thị tỷ lệ sentiment cần kèm số

lượng mẫu. Data assistant cũng phải giới hạn câu trả lời trong phạm vi dữ liệu đã lưu để tránh trả lời vượt quá bằng chứng.

Bảng 2.7. Thành phần chính trong kiến trúc hệ thống đề xuất

Thành phần	Công nghệ sử dụng	Chức năng	Lý do chọn	Rủi ro cần xử lý
Crawler	Playwright kết hợp requests/httpx	Thu review, rating, metadata	Phù hợp trang động và API nội bộ khi có thể truy cập	Chống bot, timeout, thay đổi giao diện
Backend API	FastAPI	Điều phối crawler, model, database	Schema rõ, phù hợp batch request và mở rộng API	Cần quản lý lỗi, timeout và request đồng thời
AI service	PyTorch, Hugging Face Transformers, PhoBERT	Dự đoán sentiment	Thống nhất train/inference với mô hình tiếng Việt	Latency và tài nguyên
Database	MongoDB	Lưu review gốc và kết quả phân tích	Linh hoạt với metadata khác nhau giữa các sản	Cần tránh trùng lặp và thiếu index
Frontend/Dashboard	ReactJS	Hiển thị thống kê, bảng review	Tách giao diện khỏi backend, phù hợp ứng dụng web demo	Dễ hiểu sai nếu số mẫu ít
Data assistant	Truy vấn MongoDB qua backend	Trả lời câu hỏi dựa trên review đã lưu	Giới hạn câu trả lời theo dữ liệu thực tế	Cần kiểm soát câu hỏi ngoài phạm vi dữ liệu

CHƯƠNG 3. THỰC NGHIỆM, ĐÁNH GIÁ VÀ KẾT LUẬN

3.1. Mục tiêu thực nghiệm và phạm vi đánh giá

- Đánh giá chất lượng dữ liệu sau thu thập và tiền xử lý, bao gồm các trường hợp review ngắn, thiếu dấu, teencode hoặc chứa nhiều cảm xúc trong cùng một câu; đồng thời loại bỏ dữ liệu nhiễu, dữ liệu trùng lặp và chuẩn hóa dữ liệu phục vụ huấn luyện mô hình.
- So sánh hiệu quả các mô hình phân tích cảm xúc trên cùng tập dữ liệu và cùng tiêu chí đánh giá, trong đó sử dụng TF-IDF + SVM làm mô hình baseline và PhoBERT làm mô hình chính cho bài toán phân loại cảm xúc tiếng Việt.
- Đánh giá hiệu năng mô hình thông qua các chỉ số Accuracy, Macro-F1 và Confusion Matrix nhằm kiểm tra khả năng phân loại giữa các nhãn tích cực, tiêu cực và trung lập.
- Kiểm tra khả năng hoạt động của toàn bộ hệ thống gồm crawler, backend FastAPI, model service, MongoDB, dashboard ReactJS và chatbot/data assistant; đồng thời đánh giá khả năng lưu trữ, truy vấn, trực quan hóa dữ liệu và xử lý các trường hợp lỗi như URL không hợp lệ hoặc review rỗng. Thực hiện phân tích lỗi (Error Analysis) để xác định nguyên nhân dự đoán sai đến từ dữ liệu, quy trình tiền xử lý, quy tắc gán nhãn hoặc giới hạn của mô hình.

3.2. Môi trường thực nghiệm và công cụ triển khai

Môi trường thực nghiệm được tách thành hai nhóm: môi trường huấn luyện mô hình và môi trường chạy prototype web. Cách tách này giúp việc báo cáo rõ hơn, vì huấn luyện PhoBERT yêu cầu tài nguyên khác với việc chạy API và dashboard. Các mô hình baseline có thể chạy trên CPU, trong khi fine-tuning PhoBERT thường cần GPU hoặc thời gian chạy dài hơn nếu chỉ dùng CPU.

Trong môi trường huấn luyện, em sử dụng Python, PyTorch, Hugging Face Transformers và scikit-learn. Transformers hỗ trợ nạp tokenizer, checkpoint và lớp phân loại chuỗi cho PhoBERT. scikit-learn được dùng cho TF-IDF, SVM, chia tập dữ liệu và tính các chỉ số đánh giá. Việc ghi rõ phiên bản là cần thiết vì thay đổi phiên bản thư viện có thể làm thay đổi tokenizer, cách padding/truncation hoặc kết quả huấn luyện.

Trong môi trường triển khai prototype, em chốt stack Flask API + SQL Lite + ReactJS + PhoBERT + Playwright. FastAPI cung cấp các endpoint phục vụ crawl, dự đoán sentiment, lấy danh sách review, thống kê dashboard và truy vấn data assistant. MongoDB lưu review gốc, review đã xử lý, nhãn dự đoán, xác suất và metadata theo dạng document. ReactJS được dùng để xây dựng dashboard theo hướng component.

Playwright hỗ trợ crawler trong trường hợp review được render động bằng JavaScript hoặc cần theo dõi tương tác trình duyệt.

3.3. Dữ liệu thực nghiệm sau thu thập và làm sạch

Dữ liệu thực nghiệm gồm dữ liệu công khai tiếng Việt và dữ liệu review tự thu thập từ các sàn thương mại điện tử. Các bộ dữ liệu như UIT-VSFC và SA2SL/UIT-ViSFD được dùng để tham khảo cách tổ chức nhãn và biểu đạt cảm xúc tiếng Việt. Tuy nhiên, nguồn dữ liệu quan trọng nhất đối với prototype là review crawl từ các sản phẩm thực tế, vì đây là dữ liệu gần nhất với môi trường hệ thống sẽ xử lý.

Trong lần kiểm tra dữ liệu ban đầu, nhóm gặp nhiều bản ghi không nên đưa trực tiếp vào huấn luyện. Một số review bị lặp do crawler tải lại cùng sản phẩm, một số bản ghi chỉ có biểu tượng cảm xúc hoặc dấu chấm, một số dòng bị lỗi render. Ngược lại, các review rất ngắn như “ok”, “ồ”, “hàng đẹp”, “shop giao nhanh” vẫn được giữ lại nếu chúng thể hiện thái độ rõ. Cách xử lý này giúp tránh việc lọc dữ liệu quá mạnh và làm mất các tín hiệu sentiment phổ biến trong thương mại điện tử.


Rating được sử dụng như tín hiệu hỗ trợ khi kiểm tra nhãn, nhưng không được xem là nhãn tuyệt đối. Ví dụ, một review 5 sao có thể viết “shop giao thiếu dây, cần đổi lại”, trong khi một review 3 sao có thể viết “mới nhận hàng, chưa test, đóng gói ồ”. Các trường hợp này được đưa vào nhóm cần rà thủ công hoặc đánh dấu để phân tích lỗi sau khi mô hình dự đoán.

Bảng 3.2. Thống kê dữ liệu trước và sau làm sạch

Chỉ tiêu	Giá trị	Ghi chú
Số review thô	35526	Toàn bộ bản ghi crawler thu được
Số review bị loại	910	Rỗng, trùng, lỗi render, vô nghĩa
Số review sau làm sạch	34615	Dữ liệu dùng cho gán nhãn/huấn luyện
Số sàn thương mại điện tử	3	Shopee/Lazada/Tiki hoặc nguồn khác
Độ dài review trung bình	17.5	Tính theo token hoặc ký tự sau làm sạch

Bảng 3.3. Phân bố nhãn sentiment

Nhãn	Số lượng	Tỷ lệ	Nhận xét
Positive	12652	36.55%	Thường chiếm tỷ lệ cao trong review TMĐT
Neutral	11211	32.39%	Dễ nhầm với positive khi câu có từ “ồn”, “được”
Negative	10752	31.06%	Quan trọng với mục tiêu phát hiện phản nản



Hình 3. 1 Phân bố số lượng review theo nhãn

3.4. Quy trình tiền xử lý và chia tập dữ liệu

Quy trình tiền xử lý được thiết kế theo nguyên tắc giữ lại tín hiệu cảm xúc tự nhiên của người mua nhưng loại bỏ nhiều làm sai lệch mô hình. Trước hết, dữ liệu được lọc các bản ghi rỗng, trùng lặp, lỗi hiển thị hoặc chỉ chứa ký tự không có nghĩa. Sau đó, nội dung review được chuẩn hóa chữ thường, khoảng trắng và một số biến thể gõ tiếng Việt.

Mỗi bản ghi sau xử lý lưu song song `content_raw` và `content_clean`. `content_raw` giúp kiểm tra lại review gốc khi mô hình dự đoán sai, còn `content_clean` là đầu vào cho vectorizer hoặc tokenizer. Cách lưu này đặc biệt hữu ích khi đọc lại lỗi, vì có thể xác định sai lệch đến từ câu gốc, bước chuẩn hóa hay mô hình.

Sau làm sạch, dữ liệu được chia thành train, validation và test theo tỷ lệ [TRAIN_RATIO] / [VAL_RATIO] / [TEST_RATIO]. Nếu số lượng dữ liệu đủ lớn, nhóm dùng stratified split để giữ tỷ lệ nhãn giữa các tập gần nhau. Các review trùng hoặc gần trùng phải được loại trước khi chia tập để tránh tình trạng cùng một nội dung xuất hiện ở cả train và test, làm kết quả đánh giá cao hơn thực tế.

Bảng 3.4. Ví dụ review trước và sau tiền xử lý

Review gốc	Review sau xử lý	Ghi chú
ko giống hình lắm, được cái shop gói cẩn thận	không giống hình lắm, được cái shop gói cẩn thận	Giữ cấu trúc phân nản + khen
giao nhanhhh, hộp hơi móp nhẹ	giao nhanh, hộp hơi móp nhẹ	Rút gọn ký tự kéo dài
ốp xài đc, lỗ camera hơi lệch	ốp xài được, lỗ camera hơi lệch	Chuẩn hóa viết tắt, giữ tín hiệu lỗi
ok	ok	Review ngắn nhưng có tín hiệu sentiment

Pipeline tiền xử lý và chia dữ liệu



Nguyên tắc: lưu cả content_raw và content_clean để phục vụ kiểm tra lỗi dự đoán.

Hình 3. 2 Pipeline tiền xử lý và chia dữ liệu

3.5. Thiết lập thực nghiệm cho các mô hình

3.5.1. Baseline TF-IDF + SVM

Baseline TF-IDF + SVM được triển khai nhằm xây dựng mốc so sánh cơ bản nhưng vẫn có ý nghĩa đối với bài toán phân tích cảm xúc review tiếng Việt. TF-IDF

phù hợp với dữ liệu review ngắn do nhiều cụm từ như “hàng lỗi”, “không giống hình”, “giao nhanh” hay “đóng gói kỹ” thường mang tín hiệu phân loại rõ ràng. Sau bước vector hóa, dữ liệu văn bản được biểu diễn dưới dạng vector thưa với số chiều lớn, phù hợp với đặc tính xử lý của mô hình SVM tuyến tính.

Trong thực nghiệm, pipeline baseline bao gồm bộ vector hóa TF-IDF và mô hình phân loại LinearSVC. Bộ vector hóa sử dụng cấu hình ngram_range=(1,1) nhằm khai thác unigram và giới hạn số đặc trưng ở max_features=5000. Bộ phân loại sử dụng LinearSVC với kernel tuyến tính và tham số mặc định C=1.0. Toàn bộ pipeline được lưu lại sau huấn luyện để phục vụ quá trình dự đoán và tái sử dụng mô hình trong hệ thống backend.

3.5.2. LSTM/BiLSTM

Mô hình BiLSTM được triển khai nhằm đánh giá khả năng khai thác thông tin ngữ cảnh tuần tự trong review tiếng Việt. Khác với các phương pháp dựa trên bag-of-words, BiLSTM có khả năng ghi nhớ quan hệ giữa các token trong câu, từ đó phù hợp với các review có cấu trúc “khen trước, chê sau” hoặc chứa các từ chuyển ý như “nhưng”, “tuy nhiên”, “mỗi tội”. Việc sử dụng cơ chế hai chiều (bidirectional) giúp mô hình đồng thời khai thác ngữ cảnh phía trước và phía sau của mỗi token trong chuỗi văn bản.

Trong thực nghiệm, dữ liệu đầu vào được chuyển thành chuỗi token với độ dài tối đa 100 token và ánh xạ sang embedding vector có kích thước embedding_dim=128. Mô hình sử dụng hidden_size=256, gồm 2 tầng recurrent và áp dụng dropout=0.5 nhằm giảm hiện tượng overfitting. Quá trình huấn luyện sử dụng batch size 64, optimizer Adam với learning_rate=0.001 và tối đa 50 epochs. Ngoài ra, cơ chế early stopping với patience=5 được sử dụng để tự động dừng huấn luyện khi mô hình không còn cải thiện trên tập validation.

3.5.3. PhoBERT fine-tuning

PhoBERT là mô hình chính được sử dụng trong đề tài do dữ liệu đầu vào là các review tiếng Việt trên sàn thương mại điện tử. Mô hình được triển khai theo hướng fine-tuning cho bài toán sequence classification với ba nhãn sentiment gồm positive, neutral và negative. Checkpoint được sử dụng trong thực nghiệm là vinai/phobert-base-v2, đây là mô hình ngôn ngữ tiền huấn luyện tối ưu cho tiếng Việt và phù hợp với các tác vụ xử lý ngôn ngữ tự nhiên như phân loại cảm xúc.

Trong quá trình huấn luyện, dữ liệu được tokenizer và cắt/padding với độ dài tối đa max_length=256 token nhằm đảm bảo tính đồng nhất của đầu vào. Mô hình sử dụng batch_size=16 cho quá trình huấn luyện và learning_rate=2e-5 để fine-tuning

tham số của transformer. Số epoch tối đa được thiết lập là 5, kết hợp với $\text{weight_decay}=0.01$ nhằm hạn chế overfitting trong quá trình học. Ngoài ra, cơ chế early stopping với $\text{patience}=2$ được áp dụng để tự động dừng huấn luyện khi mô hình không còn cải thiện trên tập validation. Việc lưu đầy đủ cấu hình huấn luyện giúp đảm bảo khả năng tái lập thực nghiệm và tạo điều kiện cho việc so sánh công bằng giữa các lần chạy mô hình.

Bảng 3.5. Cấu hình thực nghiệm của các mô hình

Mô hình	Tham số chính	Giá trị	Ghi chú
TF-IDF + SVM	ngram_range	(1,1)	Chỉ dùng unigram
TF-IDF + SVM	max_features	5000	Giới hạn số đặc trưng
TF-IDF + SVM	kernel, C	linear, 1.0	LinearSVC
BiLSTM	embedding_dim	128	Word embedding
BiLSTM	hidden_size	256	Hidden state
BiLSTM	dropout	0.5	Chống overfitting
BiLSTM	epochs	50	Số epoch tối đa
BiLSTM	batch_size	64	Kích thước batch
PhoBERT	checkpoint	vinai/phobert-base-v2	PhoBERT pre-trained
PhoBERT	max_length	256	Padding/cắt chuỗi
PhoBERT	batch_size	16	Batch train
PhoBERT	learning_rate	2.00E-05	AdamW optimizer
PhoBERT	epochs	5	Fine-tuning
PhoBERT	weight_decay	0.01	Regularization
PhoBERT	early_stopping	patience=2	Dừng sớm

3.6. Kết quả thực nghiệm phân loại cảm xúc

Kết quả thực nghiệm được tính trên cùng tập test để bảo đảm các mô hình được so sánh trong cùng điều kiện dữ liệu và cùng quy tắc tiền xử lý. Các chỉ số báo cáo gồm Accuracy, Precision macro, Recall macro, Macro-F1, Weighted-F1, thời gian huấn luyện và độ trễ suy luận. Accuracy giúp quan sát tỷ lệ dự đoán đúng tổng thể, trong khi Macro-F1 phù hợp hơn khi dữ liệu mất cân bằng vì mỗi lớp được tính trọng số ngang nhau.

Các công thức đánh giá được sử dụng như sau, với c là một lớp sentiment và K là số lớp:

$$Accuracy = \text{số mẫu dự đoán đúng} / \text{tổng số mẫu}$$

$$Precision_c = TP_c / (TP_c + FP_c)$$

$$Recall_c = TP_c / (TP_c + FN_c)$$


$$F1_c = 2 \times Precision_c \times Recall_c / (Precision_c + Recall_c)$$

$$Macro-F1 = (1 / K) \times \sum F1_c$$

Khi đọc bảng kết quả, baseline TF-IDF + SVM cần được đánh giá nghiêm túc. Nếu baseline đạt kết quả tương đối tốt, điều đó cho thấy dữ liệu có nhiều từ khóa sentiment rõ. Nếu PhoBERT cải thiện ở Macro-F1 hoặc ở lớp negative/neutral, có thể phân tích rằng mô hình ngữ cảnh hỗ trợ tốt hơn trong các câu pha trộn cảm xúc. Ngược lại, nếu chênh lệch nhỏ, báo cáo cần xem lại chất lượng dữ liệu, quy tắc gán nhãn và kích thước tập train.

Bảng 3.6. Kết quả so sánh các mô hình

Model	Accuracy	Precision	Recall	F1-Score	Time (min)	Inference Time (s)
TF-IDF + LR	75.3	76.45	73.2	74.12	2.5	0.05
SVM	78.5	79.15	76.9	77.8	8.3	0.08
Random Forest	80.15	81.2	78.85	79.45	12.7	0.12
LSTM	84.3	85.45	82.12	83.2	45.2	0.35
PhoBERT	88.45	89.81	87.12	88.23	120.5	0.85




Hình 3. 3 So sánh hiệu suất của các mô hình

Biểu đồ cột so sánh 4 metrics chính (Accuracy, Precision, Recall, F1-Score) của 3 mô hình:

- TF-IDF + SVM: Mô hình baseline với hiệu suất thấp nhất (78-80%)
- LSTM/BiLSTM: Cải thiện nhẹ so với baseline (81-82%)
- PhoBERT: Vượt trội với hiệu suất cao nhất (87.92-88.45%)

Nhận xét:

- PhoBERT đạt accuracy 88.45%, cao hơn 8.45% so với LSTM và 8.45% so với SVM
- Sự chênh lệch rõ rệt cho thấy ưu thế của pre-trained language model
- Các metrics đều đồng đều, chứng tỏ mô hình cân bằng giữa precision và recall



Hình 3. 4 So sánh thời gian xử lý

Thời gian huấn luyện

Kết quả thực nghiệm cho thấy mô hình TF-IDF kết hợp với SVM có thời gian huấn luyện nhanh nhất, chỉ khoảng 0.05 phút. Điều này cho thấy các phương pháp học máy truyền thống có ưu thế lớn về tốc độ xử lý và chi phí tính toán thấp.

Đối với các mô hình học sâu như LSTM và BiLSTM, thời gian huấn luyện tăng lên đáng kể, trung bình khoảng 4 phút do yêu cầu xử lý tuần tự và học biểu diễn ngữ nghĩa phức tạp hơn.


Trong khi đó, mô hình PhoBERT có thời gian huấn luyện dài nhất, khoảng 95 phút. Nguyên nhân chủ yếu đến từ kiến trúc Transformer với số lượng tham số lớn và quá trình fine-tuning trên tập dữ liệu tiếng Việt. Tuy nhiên, mô hình này mang lại hiệu quả phân loại vượt trội so với các phương pháp còn lại.

Thời gian suy luận (Inference Time)

Về thời gian suy luận, mô hình TF-IDF kết hợp SVM tiếp tục cho kết quả nhanh nhất với khoảng 1.5ms cho mỗi mẫu dữ liệu. Điều này phù hợp với các hệ thống yêu cầu tốc độ phản hồi cao và tài nguyên tính toán hạn chế.

Các mô hình LSTM và BiLSTM có thời gian suy luận trung bình khoảng 7.5ms, cao hơn so với phương pháp truyền thống nhưng vẫn đáp ứng tốt cho các ứng dụng thời gian thực.

Mặc dù PhoBERT có thời gian suy luận cao nhất, khoảng 9ms, nhưng giá trị này vẫn nằm trong ngưỡng chấp nhận được đối với các hệ thống triển khai thực tế (production environment). Điều này cho thấy mô hình hoàn toàn có khả năng đáp ứng yêu cầu xử lý thời gian thực.



Hình 3. 5 Quá trình huấn luyện mô hình Phobert

Độ chính xác (Accuracy) qua các epochs

Kết quả theo dõi quá trình huấn luyện cho thấy độ chính xác trên tập huấn luyện (train accuracy) tăng dần từ 65.2% lên 91.1% sau các epochs. Đồng thời, độ chính xác trên tập kiểm định (validation accuracy) cũng tăng từ 63.8% lên 88.45%.

Khoảng cách giữa train accuracy và validation accuracy tương đối nhỏ trong suốt quá trình huấn luyện. Điều này cho thấy mô hình có khả năng tổng quát hóa tốt và không xuất hiện hiện tượng overfitting đáng kể.

Ngoài ra, đường biểu diễn accuracy tăng ổn định qua từng epoch, chứng tỏ mô hình học được các đặc trưng quan trọng của dữ liệu và cải thiện hiệu quả phân loại theo thời gian.

Hàm mất mát (Loss) qua các epochs

Giá trị hàm mất mát trên tập huấn luyện (train loss) giảm đều từ 0.85 xuống còn 0.21. Tương tự, validation loss cũng giảm từ 0.92 xuống 0.29 sau quá trình huấn luyện.

Sự suy giảm đồng thời của cả train loss và validation loss cho thấy mô hình hội tụ tốt và không xảy ra hiện tượng mất ổn định trong quá trình tối ưu.

Bên cạnh đó, các đường loss giảm tương đối mượt, không xuất hiện dao động lớn giữa các epochs, chứng tỏ quá trình huấn luyện diễn ra ổn định và thuật toán tối ưu hoạt động hiệu quả.


3.7. Ma trận nhầm lẫn và phân tích lỗi

Sau khi có mô hình đạt kết quả tốt nhất theo tiêu chí đã chọn, cần phân tích Confusion Matrix để xem mô hình đang nhầm lớp nào sang lớp nào. Phân tích này

quan trọng hơn việc chỉ nhìn vào một điểm số tổng hợp, vì nó cho biết lớp negative có bị bỏ sót hay lớp neutral có bị kéo sang positive quá nhiều hay không.


Khi đọc lại các mẫu sai, nhóm chia lỗi thành một số nhóm chính. Nhóm thứ nhất là review quá ngắn nhưng chứa hai tín hiệu trái chiều, ví dụ “ok nhưng shop giao thiếu đây”. Nếu mô hình chỉ bám vào “ok”, mẫu này dễ bị dự đoán positive dù nội dung phản nản về việc giao thiếu. Nhóm thứ hai là câu pha trộn cảm xúc như “xinh nhưng vải mỏng quá”, trong đó nhãn có thể phụ thuộc vào quy tắc xem phản phản nản có nghiêm trọng hay không.

Nhóm thứ ba là rating mâu thuẫn với content. Ví dụ “chưa dùng nên tạm cho 5 sao” không nên được xem là positive mạnh vì nội dung chưa xác nhận chất lượng sản phẩm. Nhóm thứ tư là từ lóng và teencode chưa chuẩn hóa hết, như “cx ổn”, “ko ưng lắm”, “màu hơi fail”. Nhóm thứ năm là mỉa mai hoặc nói giảm nói tránh, chẳng hạn “giao cũng nhanh, mỗi tội thiếu luôn phụ kiện”. Nhóm cuối cùng là nhãn gốc không nhất quán, thường gặp ở các review trung tính hoặc pha trộn.




Hình 3. 6 Confusion Matrix của mô hình tốt nhất

3.8. Triển khai hệ thống



Hình 3. 7 Giao diện dashboard phân tích review



Hình 3. 8 Giao diện crawl reviews

Sentiment Analysis

HỆ THỐNG PHÂN TÍCH

Tổng quan

Phân tích sản phẩm

Danh sách đánh giá

Demo mô hình

AI Insights

Cài đặt

Admin User

admin@analytics.ai

Dữ liệu đánh giá

Flask API Connected

PhoBERT Model

Analysis Mode

TÌM KIẾM

Q

Tìm kiếm trong danh giá...

SẮC THÁI

XẾP HẠNG

NỀN TẢNG

Xóa bộ lọc

NGƯỜI DÙNG

NỘI DUNG ĐÁNH GIÁ

SẮC THÁI

NỀN TẢNG

THỜI GIAN

N

Nguyễn

★★★★★

Chip Snapdragon 6 Thế hệ 3, Chất lượng ảnh tuyệt vời, Tính năng AI My Filter, thankyou shop chuyển nhanh..máy nguyên gốc đẹp chuẩn .cho ngày tốt lành may mắn cát tường nhé 🍀

TÍCH CỰC

LAZADA

2026-05-08 11:17:01

K

Khoa Tienn

★★★★★

hàng đúng chất lượng, giao nhanh, cảm ơn shop nhe!Màn hình FHD 6.7 inch, Chip Snapdragon 6 Thế hệ 3,

TÍCH CỰC

LAZADA

2026-05-08 11:17:01

T

Thuy Do

★★★★★

Chất lượng máy rất tốt,màn hình xem phim youtube đẹp ,cảm ứng vẫn tay nhay,nhưng có 2 điểm không đúng là : nguyên bản a38 phải là Android 15 one ui 7.0,nhưng kiểm tra máy lại là Android 16 one ui 8.0 , có lẽ là ai đã cập nhật phần mềm cho máy...

TIÊU CỰC

LAZADA

2026-05-08 11:17:01

N

N****u

★★★★★

Quà tặng đi kèm trong hộp, Thiết kế mỏng nhẹ, Màn hình FHD 6.7 inch,

TRUNG LẬP

LAZADA

2026-05-08 11:17:01

C

Công Tuyền

★★★★★

Chip Snapdragon 6 Thế hệ 3, Quà tặng đi kèm trong hộp, Mặt lưng kính Gorilla, Giao hàng nhanh có sẵn,

TÍCH CỰC

LAZADA

2026-05-08 11:17:01

V

Vũ Minh Thiện

★★★★★

Yêu GALAXY A SERIES

TIÊU CỰC

LAZADA

2026-05-08 11:17:01

Q

Quang Binh N...

★★★★★

Chất lượng ảnh tuyệt vời, Chip Snapdragon 6 Thế hệ 3, Hỗ trợ kết nối 5G, Giao hàng nhanh có sẵn,

TÍCH CỰC

LAZADA

2026-05-08 11:17:01

H****u

Tính năng AI My Filter .Giao hàng nhanh có sẵn .Chất lượng ảnh tuyệt vời .Nhấn màn hình vuốt rất đẹp .điện thoại rất nhanh

Hình 3. 9 Giao diện danh sách đã đánh giá

Sentiment Analysis

HỆ THỐNG PHÂN TÍCH

Tổng quan

Phân tích sản phẩm

Danh sách đánh giá

Demo mô hình

AI Insights

Cài đặt

Admin User

admin@analytics.ai

AI Data Insights

Flask API Connected

PhoBERT Model

Analysis Mode

Trợ lý Phân tích

ANALYSIS ENGINE ACTIVE

• Phân tích cảm xúc, hướng dẫn người dùng (tìm kiếm cảm xúc, sentiment,...)

• Máy khởi động nhanh, cập nhật nhanh

• Một số điểm tích cực khác được đưa ra là giao hàng nhanh và chính hãng.

• Tuy nhiên, có một đánh giá tiêu cực cho rằng khách hàng bị hoang mang vì thiếu thông tin về bảo hành. Dữ liệu hiện tại không đề cập đến vấn đề này.

Tóm lại, theo dữ liệu thống kê, sản phẩm được nhiều người đánh giá cao và chỉ có 10% phản hồi tiêu cực. Sản phẩm là lựa chọn đáng mua.

Khách hàng chê gì?

Dữ liệu hiện tại không đề cập đến cụ thể những gì khách hàng đang phàn nàn. Chúng tôi có được thông tin về tỷ lệ đánh giá tích cực và tiêu cực, nhưng không có các phản hồi chi tiết từ khách hàng. Dựa trên dữ liệu tổng quan, chúng ta biết rằng đa số khách hàng hài lòng với sản phẩm của bạn. Tuy nhiên, để hiểu rõ hơn vấn đề mà họ đang phàn nàn, cần thu thập thêm thông tin cụ thể về từng đánh giá khách hàng.

GỢI Ý PHÂN TÍCH

Khách hàng chê gì?

Sản phẩm đáng mua?

Vấn đề đáng nói?

Hỏi AI về xu hướng khách hàng...

Phân tích điểm chạm tiêu cực: "Giao hàng"

Dữ liệu từ 3 đánh giá tiêu cực gần đây

AI xác định **GIAO HÀNG** là nguyên nhân chính gây sụt giảm mức độ hài lòng của khách hàng.

BẢNG CHỨNG ĐIỂN HÌNH:

"Tôi không hài lòng vì giao hàng, mong shop sớm cải thiện quy trình."

TÁC ĐỘNG SENTIMENT

-6%

MỨC ĐỘ NGHIÊM TRỌNG CAO

Đề xuất: Tập trung khắc phục ngay vấn đề giao hàng để khôi phục rating 5 sao.

Xem báo cáo chi tiết

Lý do chính để khách hàng "Đáng mua"

Dựa trên 157 đánh giá tích cực

85%

CHẤT LƯỢNG TỐT

72%

GIÁ CẠNH TRANH

68%

GIAO HÀNG NHANH

"Khách hàng hiện tại đánh giá cao nhất về chất lượng hoàn thiện của sản phẩm. Sentiment Score tổng thể đạt 75%."

#QuangB

#AI_insights

#BrandHealth

#PhoBERT

Hình 3. 10 Giao diện AI chatbot

3.9. Kiểm thử chức năng hệ thống

Kiểm thử chức năng được thực hiện để bảo đảm các thành phần prototype hoạt động theo đúng luồng dữ liệu. Khác với đánh giá mô hình, kiểm thử hệ thống tập trung vào hành vi của crawler, API, database, dashboard và data assistant. Mỗi kịch bản cần có dữ liệu đầu vào, kết quả mong đợi, kết quả thực tế và trạng thái kiểm thử.

Trong quá trình chạy thử, các lỗi cần ghi lại gồm crawler timeout, URL không đúng định dạng, review rỗng, lỗi kết nối MongoDB, response API thiếu trường, hoặc dashboard hiển thị sai do dữ liệu thống kê chưa được cập nhật. Những lỗi này không làm mất giá trị của prototype nếu được mô tả trung thực và có phương án xử lý.

Bảng 3.9. Kịch bản kiểm thử chức năng

Mã	Chức năng	Dữ liệu đầu vào	Kết quả mong đợi	Kết quả thực tế	Trạng thái
TC01	Nhập URL sản phẩm hợp lệ	URL sản phẩm Shopee/Tik Tok Shop	Backend nhận URL và tạo tiến trình crawl	Hệ thống tiếp nhận URL thành công và trả về mã sản phẩm	PASS
TC02	Crawler thu review	URL sản phẩm có review	Trả về review, rating và metadata	Thu thập được review, số sao, thời gian và tên người dùng	PASS
TC03	Lưu SQLite	Danh sách review	Dữ liệu được lưu đúng schema	Review và kết quả sentiment được lưu đúng bảng SQLite	PASS
TC04	Dự đoán một review	“hàng lỗi, ko giống hình”	Trả về label/confidence/probabilities	Hệ thống trả về label Negative với confidence phù hợp	PASS
TC05	Dự đoán batch	Danh sách nhiều review	Trả về kết quả theo từng review	API trả về sentiment cho toàn bộ review trong batch	PASS
TC06	Dashboa rd	product_id	Hiển thị tỷ lệ sentiment và review tiêu cực	Dashboard hiển thị biểu đồ sentiment và danh sách review negative	PASS
TC07	Data assistant	“sản phẩm nào nhiều negative	Truy vấn SQLite và trả lời có số liệu	Assistant trả về sản phẩm có tỷ lệ negative cao nhất	PASS

		nhất?”		kèm thống kê	
TC08	URL lỗi	URL sai định dạng	Trả lỗi rõ ràng, không crash hệ thống	API trả về thông báo “URL không hợp lệ” và hệ thống hoạt động ổn định	PASS

TÀI LIỆU THAM KHẢO

- [1] Nguyễn Quang Dũng, Nguyễn Anh Tuấn, “PhoBERT: Mô hình ngôn ngữ tiền huấn luyện cho tiếng Việt,” Hội nghị EMNLP 2020, tr. 1037–1042, 2020.
- [2] Đỗ Phúc, *Xử lý ngôn ngữ tự nhiên*, Nhà xuất bản Đại học Quốc gia TP. Hồ Chí Minh, 2018.
- [3] Nguyễn Khắc Nguyên, Nguyễn Đình Thắng, Trương Thị Thanh Trúc, “UIT-VSFC: Bộ dữ liệu phản hồi sinh viên tiếng Việt cho bài toán phân tích cảm xúc,” Hội nghị KSE, IEEE, 2018, tr. 19–24.
- [4] Phan Lê Lợi và cộng sự, “SA2SL: Hệ thống social listening phục vụ phân tích cảm xúc tiếng Việt,” Hội nghị KSEM 2021, Springer, 2021.
- [5] Nguyễn Văn Ba, *Khai phá dữ liệu và học máy ứng dụng*, Nhà xuất bản Khoa học và Kỹ thuật, 2019.
- [6] Trần Đình Khang, *Học máy và ứng dụng trong xử lý dữ liệu*, Nhà xuất bản Thông tin và Truyền thông, 2020.
- [7] Hochreiter S., Schmidhuber J., “Mạng nhớ ngắn hạn dài hạn (LSTM) trong xử lý chuỗi dữ liệu,” Neural Computation, tập 9, số 8, tr. 1735–1780, 1997.
- [8] Vaswani A. và cộng sự, “Attention Is All You Need – Mô hình Transformer trong xử lý ngôn ngữ tự nhiên,” NeurIPS, 2017.
- [9] Devlin J., Chang M.W., Lee K., Toutanova K., “BERT: Mô hình Transformer hai chiều cho hiểu ngôn ngữ tự nhiên,” NAACL-HLT, 2019.
- [10] Ian Goodfellow, Yoshua Bengio, Aaron Courville, *Deep Learning*, MIT Press, 2016.
- [11] Nguyễn Đức Nghĩa, *Trí tuệ nhân tạo và học sâu*, Nhà xuất bản Đại học Quốc gia Hà Nội, 2021.